



โครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์สำหรับการสร้างแบบจำลองและพยากรณ์
พฤติกรรมไม่เป็นเชิงเส้นของราคาอปชันบิตคอยน์

พรชัย คำแดง

ปริญญาานิพนธ์เสนอต่อมหาวิทยาลัยรามคำแหง
เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญา
วิทยาศาสตรบัณฑิต (ฟิสิกส์)
ปีการศึกษา 2568

โครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์สำหรับการสร้างแบบจำลองและพยากรณ์
พฤติกรรมไม่เป็นเชิงเส้นของราคาออปชันบิตคอยน์

พรชัย คำแดง

ปริญญาานิพนธ์เสนอต่อมหาวิทยาลัยรามคำแหง
เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญา
วิทยาศาสตรบัณฑิต (ฟิสิกส์)
ปีการศึกษา 2568
ลิขสิทธิ์ของมหาวิทยาลัยรามคำแหง

Physics-Informed Neural Network for modeling and forecasting nonlinear
Bitcoin Option Pricing

PORNCHAI KHAMDAENG

A THESIS PRESENTED TO RAMKHAMHAENG UNIVERSITY
IN PARTIAL FULFILLMENT OF THE REQUIREMENTS
FOR THE DEGREE OF BACHELOR OF SCIENCE
(PHYSICS)

2025

COPYRIGHTED BY RAMKHAMHAENG UNIVERSITY

โครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์สำหรับการสร้างแบบจำลองและพยากรณ์
ราคาออปชันบิตคอยน์ที่มีความไม่เป็นเชิงเส้น

นายพรชัย คำแดง

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาฟิสิกส์
มหาวิทยาลัยรามคำแหง
ปีการศึกษา 2568

คณะกรรมการสอบปริญญานิพนธ์

..... ประธานกรรมการสอบปริญญานิพนธ์
(.....)

..... กรรมการสอบปริญญานิพนธ์
(.....)

..... กรรมการสอบปริญญานิพนธ์
(.....)

..... อาจารย์ที่ปรึกษาปริญญานิพนธ์
(รศ.ดร.สุขสันต์ สุวรรณรัตน์)

ชื่อเรื่องวิทยานิพนธ์	โครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์สำหรับการสร้างแบบจำลองและพยากรณ์พฤติกรรมไม่เป็นเชิงเส้นของราคาออปชันบิตคอยน์
ชื่อผู้เขียน	นายพรชัย คำแดง
อาจารย์ที่ปรึกษา	รศ.ดร.สุขสันต์ สุวรรณรัตน์
ชื่อปริญญา	วิทยาศาสตรบัณฑิต
สาขาวิชา	ฟิสิกส์
ปีการศึกษา	2568

บทคัดย่อ

การวิจัยนี้มีวัตถุประสงค์เพื่อศึกษาและพัฒนาแบบจำลองโครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์ (Physics-Informed Neural Networks; PINN) เพื่อหาผลเฉลยสมการแบล็ก-โชลส์ (Black-Scholes Equation) สำหรับการประมาณราคาออปชันบิตคอยน์ โดยดำเนินการทดลองผ่านการพัฒนาโมเดล 2 รูปแบบ ได้แก่ PINN Model A ที่รับอินพุตพื้นฐาน 2 ตัวแปร (ราคาบิตคอยน์และเวลา) ภายใต้สมมติฐานค่าตัวแปรคงที่ และ PINN Model B ที่ขยายขอบเขตเป็นอินพุต 6 ตัวแปร ซึ่งรวมถึงค่าความผันผวนและอัตราดอกเบี้ยแบบไม่คงที่ได้จากการเรียนรู้ข้อมูลตลาดจริง ผลการวิจัยพบว่า PINN Model A มีประสิทธิภาพสูงมากเมื่อทดสอบกับข้อมูลจำลอง โดยมีค่าเฉลี่ยของ RMSE = 85.18 และ $R = 0.9899$ ในขณะที่ PINN Model B สามารถทำนายราคาออปชันบิตคอยน์จริงที่ใช้ฝึกได้อย่างแม่นยำ โดยมี RMSE = 45.47 และ $R = 0.99$ นอกจากนี้การประยุกต์ใช้แบบทำนายล่วงหน้า ยังแสดงให้เห็นถึงแนวโน้มที่อาจสอดคล้องกับราคาตลาดจริง

Thesis Title	Physics-Informed Neural Network for modeling and forecasting nonlinear Bitcoin Option Pricing
Student's Name	Mr. Pornchai Khamdaeng
Project Advisor	Asst. Prof. Dr. Suksan Suwanarat
Degree Sought	Bachelor of Science
Major	Physics
Academic Year	2025

ABSTRACT

This research aims to study and develop Physics-Informed Neural Networks (PINNs) to solve the Black-Scholes Equation for Bitcoin option pricing. The experiment was conducted through the development of two model variations: PINN Model A, which accepts two fundamental inputs (Bitcoin price and time) under the assumption of constant parameters, and PINN Model B, which expands the scope to six inputs, incorporating dynamic volatility and risk-free interest rates derived from real market data learning. The results indicate that PINN Model A is highly effective when tested with simulated data, achieving an average RMSE of 85.18 and R of 0.9899. Meanwhile, PINN Model B can accurately predict the real Bitcoin option prices used for training, with an RMSE of 45.47 and R of 0.99. Furthermore, the application of walk-forward prediction demonstrates trends that are consistent with actual market prices.

กิตติกรรมประกาศ

ปริญญานิพนธ์ฉบับนี้ สำเร็จลุล่วงได้ด้วยความกรุณาอย่างยิ่งของ รองศาสตราจารย์ ดร.สุขสันต์ สุวรรณรัตน์ อาจารย์ที่ปรึกษาปริญญานิพนธ์ผู้ซึ่งได้กรุณาให้คำแนะนำอย่างลึกซึ้งในการประยุกต์ใช้องค์ความรู้ทางฟิสิกส์และคณิตศาสตร์มาสู่การสร้างแบบจำลองทางการเงิน ท่านได้ให้คำปรึกษาทั้งในด้านทฤษฎี แนวทางการเขียนโปรแกรม และการตรวจสอบแก้ไขข้อบกพร่องต่าง ๆ จนกระทั่ง โครงการนี้สำเร็จสมบูรณ์ ผู้วิจัยขอกราบขอบพระคุณมา ณ โอกาสนี้ด้วยความเคารพอย่างสูง

ผู้วิจัยขอกราบขอบพระคุณ คณาจารย์ภาควิชาฟิสิกส์ คณะวิทยาศาสตร์ทุกท่าน ที่ได้ประสิทธิ์ประสาทวิชาความรู้ และให้คำแนะนำที่เป็นประโยชน์ในตลอดระยะเวลาของการศึกษาของงานวิจัยครั้งนี้

ผู้วิจัยขอขอบคุณ Ashish Dhiman และ Yibei Hu เจ้าของงานวิจัยต้นแบบที่จุดประกายการประยุกต์ใช้แนวคิดเรื่องโครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์ (PINN) สำหรับการทำนายราคาออปชันบิตคอยน์ ขอขอบคุณชุมชนนักพัฒนาโปรแกรมภาษา Python และไลบรารี PyTorch ที่เอื้อเพื่อเครื่องมือซอฟต์แวร์รหัสเปิด (Open Source Software) ประสิทธิภาพสูงสำหรับการคำนวณเชิงลึก และขอขอบคุณ Binance API ที่อนุเคราะห์ข้อมูลราคาตลาดจริง ซึ่งเป็นส่วนสำคัญอย่างยิ่งในการทดสอบและพัฒนา PINN เพื่อหาค่าความผันผวน (σ) และค่าอัตราดอกเบี้ยที่ปราศจากความเสี่ยง (r) ที่มีการเปลี่ยนแปลงจริงตามเวลาในงานวิจัยครั้งนี้

ผู้วิจัยขอขอบคุณมหาวิทยาลัยรามคำแหง ซึ่งเป็นสถานศึกษาที่ให้โอกาสในการเรียนรู้ส่งเสริมการค้นคว้าอิสระและเป็นแหล่งรวบรวมวิชาการสำคัญอย่างยิ่งที่เกื้อหนุนให้การศึกษาระดับปริญญาตรีเป็นไปอย่างสมบูรณ์

ท้ายที่สุด คุณค่าและประโยชน์อันพึงมีจากปริญญานิพนธ์ฉบับนี้ ผู้วิจัยขออุทิศให้เป็นกตเวทิตาคุณแด่ บิดา มารดา ครอบครัว และครูอาจารย์ทุกท่านที่ได้ประสิทธิ์ประสาทวิชา จนทำให้ผู้วิจัยสามารถลุล่วงการจัดทำปริญญานิพนธ์ฉบับนี้ได้สำเร็จ

พรชัย คำแดง

สารบัญ

	หน้า
บทคัดย่อภาษาไทย.....	(4)
บทคัดย่อภาษาอังกฤษ.....	(5)
กิตติกรรมประกาศ.....	(6)
สารบัญ.....	(7)
สารบัญตาราง.....	(9)
สารบัญภาพประกอบ.....	(11)
บทที่	
1 บทนำ.....	1
ความเป็นมาและความสำคัญของปัญหา.....	1
วัตถุประสงค์ของการวิจัย.....	3
ขอบเขตของการวิจัย.....	4
ประโยชน์ที่คาดว่าจะได้รับ.....	5
2 วรรณกรรมที่เกี่ยวข้อง.....	6
กระบวนการสุ่มและการเคลื่อนที่แบบบราวน์.....	6
สมการเชิงอนุพันธ์ย่อยในฟิสิกส์และเศรษฐฟิสิกส์.....	10
การใช้บทนิยามเลมมาของอิโตะ.....	12
แบบจำลองแบล็ก-โฮลส์.....	13
โครงข่ายประสาทเทียม.....	18
การหาอนุพันธ์เชิงอัตโนมัติ.....	20
สถาปัตยกรรมและฟังก์ชันความสูญเสียเชิงฟิสิกส์.....	21

บทที่	หน้า
3 วิธีดำเนินการวิจัย.....	25
เครื่องมือที่ใช้ในการวิจัย.....	25
ข้อมูลการวิจัย.....	26
วิธีการวิจัย.....	28
4 ผลการทดลองและวิเคราะห์ข้อมูล.....	43
การทดสอบ PINN แบบ 1).....	43
การทดสอบ PINN แบบ 2).....	57
การทดสอบประยุกต์ใช้ PINN แบบ 2).....	61
5 สรุปผลการวิจัยและข้อเสนอแนะ.....	63
สรุปผลการวิจัย.....	63
ข้อเสนอแนะ.....	64
ภาคผนวก.....	65
บรรณานุกรม.....	68
ประวัติผู้เขียน.....	70

สารบัญตาราง

ตาราง	หน้า
3.1 ตัวแปรข้อมูลอุปชันบิตคอยน์สำหรับ PINN Model.....	29
3.2 ข้อมูลตัวแปรในโครงสร้าง PINN Model A.....	30
3.3 ตัวแปรฝึก PINN Model A.....	30
3.4 ตัวแปรของสมการ RMSE และ R.....	34
3.5 ความหมายตัวแปรของแบบจำลอง GBM.....	35
3.6 ข้อมูลที่ได้รับจาก Binance API.....	36
3.7 ชุดตัวแปรการฝึก $PINN_{\sigma, r}$ เพื่อหา σ_{pred} และ r_{pred}	37
3.8 ข้อมูลรวมจากข้อ 1.8.9 และ $PINN_{\sigma, r}$ ที่เพิ่มเข้ามา เมื่อ $K = 111600$ และ $T = 0.01916496$ เป็นค่าคงที่ เนื่องจากพิจารณาแค่สัญญาเดียว...	38
3.9 ข้อมูล PINN Model B.....	38
3.10 ชุดข้อมูลตัวแปรการฝึก PINN Model B.....	39
3.11 ระเบียบการประยุกต์ใช้ PINN Model B เพื่อทำนายอนาคต.....	42
4.1 ข้อมูลการฝึก PINN Model A ในแต่ละรอบการฝึก.....	46
4.2 ค่า RMSE และ R จากผลการทดสอบโมเดลด้วยชุดข้อมูลทดสอบ $[S_{range}, t_{range}]_{grid}$ จำนวน 10,000 จุด กับ PINN Model A (result_14)....	48
4.3 ค่า RMSE และ R จากผลการทดสอบโมเดลด้วยชุดข้อมูลราคาอุป ชันบิตคอยน์จำลองรายชั่วโมง $[S, t]_{sim}$ จำนวน 10 ไฟล์ (simdata1.csv ถึง simdata10.csv) กับ PINN Model A (result_14).....	54
4.4 ค่า RMSE และ R จากผลการทดสอบโมเดลด้วยชุดข้อมูลจริง $[S,$ $t]_{real}$ จากไฟล์ klines.csv กับ PINN Model A (result_14) เทียบกับ V_{real}	56

ตาราง	หน้า
4.5 ข้อมูลการฝึก PINN Model B ในแต่ละรอบการฝึก เมื่อ β คือ Current Weight.....	59
4.6 ค่า RMSE และ R จากผลการทดสอบ PINN Model B ด้วยชุดข้อมูล อินพุตจริง [$S_{\text{real}}, t_{\text{real}}, \sigma_{\text{pred}}, r_{\text{pred}}, K_{\text{const}}, T_{\text{const}}$] ด้วยการเทียบ V_{real} และ V_{pred}	60
4.7 ค่า RMSE และ R จากผลการทดสอบโมเดล PINN _{n+0} ถึง PINN _{n+9} ด้วยชุดข้อมูลอินพุตจริง [$S_{\text{real}}, t_{\text{real}}, \sigma_{\text{pred}}, r_{\text{pred}}, K_{\text{const}}, T_{\text{const}}$] ด้วยการเทียบ V_{real} และ V_{pred} จำนวน 10 ตำแหน่ง.....	62

สารบัญภาพ

ภาพ	หน้า
2.1 การเคลื่อนที่อย่างสะเปะสะปะของอนุภาคขนาดเล็กจากจุดเริ่มต้นถึงจุดสุดท้าย	6
2.2 ลักษณะเฉพาะของการแพร่ของอนุภาคบราวน์	7
2.3 ข้อมูลการจำลองเส้นทางสุ่มของกระบวนการเคลื่อนที่แบบ ABM.....	8
2.4 ข้อมูลการจำลองเส้นทางสุ่มของกระบวนการเคลื่อนที่แบบ GBM.....	9
2.5 ข้อมูลการแจกแจงความน่าจะเป็นสำหรับกระบวนการเดินสุ่มแบบ 1 มิติ.....	10
2.6 สถาปัตยกรรมโครงข่ายประสาทเทียมแบบ MLP และกลไกการคำนวณของนิวรอนเดี่ยว.....	18
2.7 กรอบแนวคิดเชิงสถาปัตยกรรมและกระบวนการคำนวณของโครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์.....	22
3.1 ตัวอย่างกราฟแท่งเทียนของออปชันบิตคอยน์บนแพลตฟอร์ม Binance.....	26
3.2 ข้อมูลสัญญาบิตคอยน์ออปชันบนแพลตฟอร์มไบแนนซ์ (Binance) ของสัญญาในภาพ 3.1.....	27
3.3 ตัวอย่างกราฟแท่งเทียนของราคาบิตคอยน์บนแพลตฟอร์มไบแนนซ์ (Binance).....	28

ภาพ	หน้า
4.1 การกระจายตัวของจุดข้อมูล (Data Sampling) ที่ใช้ในการฝึก PINN Model A โดยการรันสคริปต์ btcusdt_call_pricing_mlp.py (result_14).....	43
4.2 ค่า Total Loss (Moving Average) ของ Model A ที่ฝึก 80,000 รอบ โดยการรันสคริปต์ btcusdt_call_pricing_mlp.py (result 14).....	44
4.3 Training Curves ของ $Loss_{total}$, $Loss_{ivp_bvp}$, $Loss_{BS}$, $Loss_{bvp1}$, $Loss_{bvp2}$ และ $Loss_{ivp}$ ของการฝึก PINN Model A โดยการรันสคริปต์ btcusdt_call_pricing_mlp.py (result_14).....	45
4.4 การเปรียบเทียบพื้นที่ผิว 3 มิติของผลเฉลยระหว่าง V_{sol} และ V_{pred} โดยการรันสคริปต์ btcusdt_call_pricing_mlp.py (result 14).....	47
4.5 แผนภาพกระจายเปรียบเทียบผลเฉลยเชิงวิเคราะห์ (V_{sol}) และ ราคาประมาณจาก PINN Model A (V_{pred}) โดยที่เส้นประสีแดงคือเส้นเปรียบเทียบในอุดมคติ (Ideal Match) $y = x$ โดยการรันสคริปต์ btcusdt_call_pricing_mlp.py (result 14).....	47
4.6 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจากผลเฉลยเชิงวิเคราะห์ (V_{sol}) กับราคาอปชันจาก PINN Model A (V_{pred}) บนเส้นทางราคาบิตคอยน์จำลอง จากไฟล์ simdata01.csv.....	49
4.7 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจากผลเฉลยเชิงวิเคราะห์ (V_{sol}) กับราคาอปชันจาก PINN Model A (V_{pred}) บนเส้นทางราคาบิตคอยน์จำลอง จากไฟล์ simdata02.csv.....	49
4.8 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจากผลเฉลยเชิงวิเคราะห์ (V_{sol}) กับราคาอปชันจาก PINN Model A (V_{pred}) บนเส้นทางราคาบิตคอยน์จำลอง จากไฟล์ simdata03.csv.....	50

ภาพ	หน้า
4.9 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจากผลเฉลยเชิงวิเคราะห์ (V_{sol}) กับราคาอปชันจาก PINN Model A (V_{pred}) บนเส้นทางราคาบิตคอยน์จำลอง จากไฟล์ simdata04.csv.....	50
4.10 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจากผลเฉลยเชิงวิเคราะห์ (V_{sol}) กับราคาอปชันจาก PINN Model A (V_{pred}) บนเส้นทางราคาบิตคอยน์จำลอง จากไฟล์ simdata05.csv.....	51
4.11 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจากผลเฉลยเชิงวิเคราะห์ (V_{sol}) กับราคาอปชันจาก PINN Model A (V_{pred}) บนเส้นทางราคาบิตคอยน์จำลอง จากไฟล์ simdata06.csv.....	51
4.12 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจากผลเฉลยเชิงวิเคราะห์ (V_{sol}) กับราคาอปชันจาก PINN Model A (V_{pred}) บนเส้นทางราคาบิตคอยน์จำลอง จากไฟล์ simdata07.csv.....	52
4.13 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจากผลเฉลยเชิงวิเคราะห์ (V_{sol}) กับราคาอปชันจาก PINN Model A (V_{pred}) บนเส้นทางราคาบิตคอยน์จำลอง จากไฟล์ simdata08.csv.....	52
4.14 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจากผลเฉลยเชิงวิเคราะห์ (V_{sol}) กับราคาอปชันจาก PINN Model A (V_{pred}) บนเส้นทางราคาบิตคอยน์จำลอง จากไฟล์ simdata09.csv.....	53
4.15 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจากผลเฉลยเชิงวิเคราะห์ (V_{sol}) กับราคาอปชันจาก PINN Model A (V_{pred}) บนเส้นทางราคาบิตคอยน์จำลอง จากไฟล์ simdata10.csv.....	53
4.16 กราฟแท่งเทียนของราคาอปชันบิตคอยน์ V_{real} และราคาบิตคอยน์ S_{real} แบบรายชั่วโมงย้อนหลัง.....	55

ภาพ	หน้า
4.17 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{real} และราคาอปชัน V_{pred} จาก PINN Model A.....	56
4.18 ชุดข้อมูลความผันผวน σ_{pred} ที่ประมาณได้จากตลาดจริงด้วย PINN $_{\sigma,r}$ เทียบกับราคาปิดคอยน์ S_{real} โดยการรันสคริปต์ real_btcsdt_implied_params_mlp.py (run_4).....	57
4.19 ชุดข้อมูลความผันผวน r_{pred} ที่ประมาณได้จากตลาดจริงด้วย PINN $_{\sigma,r}$ เทียบกับราคาปิดคอยน์ S_{real} โดยการรันสคริปต์ real_btcsdt_implied_params_mlp.py (run_4).....	58
4.20 ข้อมูล Training Curves แสดง $Loss_{\text{total}}$, $Loss_{\text{data}}$ และ $Loss_{\text{pde}}$ ของการฝึก PINN Model B โดยการรันสคริปต์ real_btcsdt_call_pricing_mlp_6inputs.py (result_8).....	58
4.21 แผนภาพกระจายเปรียบเทียบ V_{real} (แกน Y) และ ราคาประมาณจาก PINN Model B (V_{pred}) โดยการรันสคริปต์ real_btcsdt_call_pricing_mlp_6inputs.py (result_8).....	60
4.22 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{real} และราคาอปชัน V_{pred} จาก PINN Model B บนเส้นทางราคา S_{real} โดยการรันสคริปต์ real_btcsdt_call_pricing_mlp_6inputs.py (result_8).....	61
4.23 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{real} และ V_{pred} จาก PINN Model B บน S_{real} และผลการทำนายราคาอปชัน 10 จุดข้อมูลจาก PINN $_{n+0}$ ถึง PINN $_{n+9}$ แบบ Model B.....	62

บทที่ 1

บทนำ

ความเป็นมาและความสำคัญของปัญหา

การสร้างแบบจำลองในสาขาฟิสิกส์และเศรษฐฟิสิกส์ที่เกี่ยวข้องกับระบบไม่เป็นเชิงเส้นที่เปลี่ยนแปลงตามเวลาเป็นหัวใจสำคัญของการทำความเข้าใจพฤติกรรมต่าง ๆ พฤติกรรมดังกล่าวมักประกอบด้วยระบบที่ซับซ้อนและมีลักษณะข้อมูลที่ไม่เป็นเชิงเส้นตามเวลาและไวต่อการเปลี่ยนแปลงสภาวะเงื่อนไขเริ่มต้น (Chaos) ซึ่งยากต่อการทำนายระบบในช่วงเวลามาก ๆ โดยทั่วไปแบบจำลองของระบบสามารถเขียนอยู่ในรูปแบบสมการเชิงอนุพันธ์ได้เพื่อใช้ศึกษาพฤติกรรมทางกายภาพภายใต้เงื่อนไขที่กำหนดด้วยความก้าวหน้าของเทคโนโลยีข้อมูลและคอมพิวเตอร์ความเร็วสูง ทำให้อัลกอริทึมโครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์ (Physics-Informed Neural Networks; PINNs) เกิดขึ้นได้ ซึ่งเป็นวิธีการใหม่เพื่อแก้ปัญหาสมการเชิงอนุพันธ์ของอนุกรมเวลาที่ไม่เป็นเชิงเส้น วิธีการ PINN ให้ผลลัพธ์ที่แม่นยำและมีความยืดหยุ่น ซึ่งขึ้นอยู่กับข้อมูลที่ใช้ฝึก ตัวอย่างเช่น แบบจำลอง PINNs ที่ถูกสร้างขึ้นเพื่อเรียนรู้พฤติกรรมของระบบที่ไม่เป็นเชิงเส้น การเคลื่อนที่ของของไหล การแพร่ของความร้อน และการแผ่ของคลื่นตามแบบทฤษฎีควอนตัม เป็นต้น

ในงานวิจัยนี้ เราศึกษาพฤติกรรมทางกายภาพของอนุกรมเวลาที่ไม่เป็นเชิงเส้นเพื่อประเมินราคาออปชันบิตคอยน์ โดยใช้สมการเชิงอนุพันธ์ย่อยแบบจำลองแบล็ก-โชลส์ (Black-Scholes Partial Differential Equation Model; BSPDEM) สมการแบล็ก-โชลส์เป็นแบบจำลองข้อมูลราคาของผลิตภัณฑ์ทางการเงินที่เปลี่ยนแปลงตามเวลาแบบไม่เป็นเชิงเส้น เช่น ราคาออปชันของหุ้น (ราคาออปชันคือสัญญาที่ให้สิทธิ์แก่นักลงทุนเพื่อ “ซื้อ” หรือ “ขาย” สินทรัพย์อ้างอิงในราคาที่ตกลงไว้ล่วงหน้าและภายในระยะเวลาที่กำหนด) และราคาออปชันของสกุลเงินดิจิทัล (Cryptocurrency) เป็นต้น การแก้สมการ BSPDE ใช้วิธี PINN ที่ถูกพัฒนาขึ้นและฝึกสอนด้วยชุดข้อมูล (Dataset)

ราคาแบบลุ่มภายใต้สภาวะเงื่อนไขขอบเขตของราคาอปชันบิตคอยน์ (บิตคอยน์ (Bitcoin) คือสกุลเงินดิจิทัลตัวแรกของโลกที่ทำงานบนระบบกระจายศูนย์โดยไม่จำเป็นต้องมีตัวกลางอย่างธนาคารหรือรัฐบาลและถูกสร้างขึ้นในปี 2009 โดยบุคคลหรือกลุ่มบุคคลที่ไม่ทราบชื่อจริงที่ใช้นามแฝงว่า ซาโตชิ นากาโมโตะ (Satoshi Nakamoto)) ระบบ PINNs ที่พัฒนาขึ้นใช้โหนดที่มีฟังก์ชันกระตุ้น “Tanh” ซึ่งสอดคล้องกับการเปลี่ยนแปลงขึ้นลงแบบจับปล้น ชุดข้อมูลฝึก PINNs มี 2 แบบ ดังนี้ 1) ชุดข้อมูลราคาจำลองแบบลุ่มโดยกำหนดช่วงพิสัยของราคา (S_{range}) และช่วงเวลา (t_{range}) ของสัญญา และชุดข้อมูลพารามิเตอร์คงที่ ซึ่งประกอบด้วยราคาใช้สิทธิ (Strike Price; K) อัตราผลตอบแทนปราศจากความเสี่ยง (Risk Free rate; r) และความผันผวน (Volatility; σ) 2) ชุดข้อมูลราคาจริงภายใต้ค่าคงที่พารามิเตอร์ที่ได้รับจากตลาดจริงแบบเวลาจริง (Real-time) PINNs แบบที่ 1) ถูกฝึกโดยใช้ชุดข้อมูลราคาอปชันบิตคอยน์ที่ได้รับจากการคำนวณผลเฉลยจริงของสมการแบล็ค-โชลส์ และ PINN แบบที่ 2) ถูกฝึกโดยใช้ข้อมูลราคาอปชันบิตคอยน์จริง ผลลัพธ์ของการฝึกด้วยชุดข้อมูลทั้ง 2 แบบบ่งชี้ว่า BSPDEM PINNs มีประสิทธิภาพที่ดี ค่าเฉลี่ยของความคลาดเคลื่อนกำลังสองระหว่างค่าจริงกับค่าที่โมเดลคาดการณ์ไว้ (Mean Squared Error; MSE) มีค่าต่ำ ซึ่งแสดงว่า BSPDEM PINNs มีความแม่นยำสูงและค่าฟังก์ชันความสูญเสีย (Loss function) มีแนวโน้มเข้าใกล้ศูนย์

ผลลัพธ์ของการใช้ BSPDEM PINNs ที่ได้รับการฝึกฝนแล้วได้ถูกประเมินประสิทธิภาพเพื่อตรวจสอบความแม่นยำของแบบจำลอง ด้วยการเทียบผลการทำนายราคาด้วย BSPDEM PINNs กับผลเฉลยเชิงวิเคราะห์ (Analytical Solution) จากสมการแบล็ค-โชลส์ และกับข้อมูลตลาดจริง การประเมินประสิทธิภาพแสดงให้เห็นว่า BSM PINNs ทั้งสองแบบที่มีรอบฝึก 80000 (epoch) และ 40000 (epoch) นั้นมีค่ารากที่สองของค่าเฉลี่ยของความคลาดเคลื่อนยกกำลังสอง (Root Mean Squared Error; RMSE) (การวัดค่าความคลาดเคลื่อนเฉลี่ยของแบบจำลอง โดยคำนวณจาก RMSE ใช้เพื่อประเมินประสิทธิภาพของโมเดลโดยค่าที่วัดต่ำกว่าจะดีกว่า แสดงถึงการทำนายที่แม่นยำและมีความคลาดเคลื่อนน้อยกว่า) คือ $RMSE = 184.78$, $R = 0.8477$ และ $RMSE = 45.47$, $R = 0.9911$ ตามลำดับ เมื่อตัวแปร R คือค่าสัมประสิทธิ์ สหสัมพันธ์ (Correlation Coefficient) ผลลัพธ์ดังกล่าวแสดงให้เห็นชัดว่าแบบจำลอง PINNs สามารถประเมินพฤติกรรมของ

ราคาอปชันบิตคอยน์ได้เป็นอย่างดี ซึ่งแนวโน้มของ ราคามีทิศทางสอดคล้องกัน BSPDEM PINNs เหล่านี้ยังสามารถเพิ่มความแม่นยำมากขึ้น โดยการปรับอัตราการฝึก การเพิ่ม โหนดและเลเยอร์ของโครงข่ายประสาทเทียม และการใช้ชุดข้อมูลจริงจำนวนจำนวน มากขึ้น การออกแบบและพัฒนาสถาปัตยกรรม BSPDEM PINNs ขั้นสูงที่รวบรวมข้อมูล จริงและพารามิเตอร์ต่าง ๆ ของตลาดแบบเวลา จริงด้วยการสกัดค่าพารามิเตอร์ต่าง ๆ แบบเวลาจริงจากข้อมูลของช่วงเวลาที่กำหนดจะ ช่วยเพิ่มความแม่นยำมากขึ้น และช่วยพัฒนา BSPDEM PINNs สำหรับทำนายพฤติกรรม การเปลี่ยนแปลงในเวลา ที่เกี่ยวกับผลิตภัณฑ์ทางการเงินแบบเวลาจริงได้

วัตถุประสงค์ของการวิจัย

1. เพื่อสร้าง PINN Model A และหาผลเฉลี่ยพฤติกรรมทางกายภาพของอนุกรม เวลาที่ไม่เป็นเชิงเส้น (Nonlinear time series) โดยใช้การฝึก PINN ด้วย BSPDEM
2. เพื่อใช้ PINN Model A และหาผลเฉลี่ยพฤติกรรมที่ไม่เป็นเชิงเส้นของราคา อปชันบิตคอยน์จำลอง
3. เพื่อสร้าง PINN Model B และหาผลเฉลี่ยพฤติกรรมทางกายภาพของอนุกรม เวลาที่ไม่เป็นเชิงเส้นราคาอปชันบิตคอยน์จริง โดยใช้การฝึก PINN ด้วยสมการ PDE ของ BSM ข้อมูลราคาอปชันบิตคอยน์จริงได้รับจาก Binance API
4. เพื่อใช้ PINN Model B และหาผลเฉลี่ยพฤติกรรมที่ไม่เป็นเชิงเส้นของราคา อปชันบิตคอยน์จริง
5. เพื่อสร้าง PINN Model แบบ B โดยการฝึก PINNs แบบการปรับจูนอย่างละเอียด (Fine-tuning) ด้วย BSPDEM และข้อมูลราคาอปชันบิตคอยน์จริง
6. ทำนายราคาบิตคอยน์อปชันจริง โดยใช้ PINN Model แบบ B ที่ฝึกแล้ว และ ข้อมูลราคาอปชันบิตคอยน์จริง

ขอบเขตของการวิจัย

การวิจัยนี้มุ่งเน้นการศึกษาและพัฒนากระบวนการประมาณราคาออปชันบิตคอยน์ประเภท European Call Option โดยประยุกต์ใช้โครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์ เพื่อหาผลเฉลยของสมการแบล็ก-โชลส์ (Black-Scholes Equation) ซึ่งครอบคลุมการทดสอบกับชุดข้อมูล 2 ประเภท ได้แก่ ข้อมูลจำลองที่สร้างขึ้นมาจากกระบวนการ Geometric Brownian Motion (GBM) เพื่อตรวจสอบความแม่นยำตามทฤษฎี และข้อมูลตลาดจริงย้อนหลังแบบรายชั่วโมงของราคาบิตคอยน์ (BTCUSDT) และราคาออปชันที่รวบรวมผ่าน Binance API โดยขอบเขตของตัวแปรและแบบจำลองจะแบ่งออกเป็น 2 ส่วนหลัก คือ การพัฒนา PINN Model A ที่รับอินพุตพื้นฐาน 2 ตัวแปร (ราคาบิตคอยน์และเวลา) ภายใต้สมมติฐานค่าความผันผวนและอัตราดอกเบี้ยคงที่ และการพัฒนา PINN Model B ที่ได้ขยายขอบเขตให้รองรับอินพุต 6 ตัวแปร รวมถึงค่าความผันผวนและอัตราดอกเบี้ยแบบพลวัต (Dynamic) ที่ได้จากการประมาณค่าด้วยโครงข่ายประสาทเทียมอีกชุดหนึ่งเพื่อให้สอดคล้องกับสถานะตลาดจริง การดำเนินงานทั้งหมดนี้พัฒนาบนภาษา Python โดยใช้ไลบรารี PyTorch สำหรับสร้างและฝึกสอนโมเดลร่วมกับไลบรารี Pandas สำหรับการจัดการและวิเคราะห์ข้อมูลเพื่อแสดงให้เห็นถึงประสิทธิภาพและความเป็นไปได้ที่จะใช้ PINNs ในการทำนายราคาออปชันในสถานะต่างๆ

ประโยชน์ที่คาดว่าจะได้รับ


1. ได้แบบจำลองโครงข่ายประสาทเทียม (PINN) ที่สามารถหาผลเฉลย Black-Scholes PDE เพื่อประเมินราคาออปชันบิตคอยน์ได้อย่างถูกต้องที่สุด ทั้งกับข้อมูลจำลองและข้อมูลตลาดจริง
2. ได้ทราบว่า การเพิ่มตัวแปรที่มีค่าเปลี่ยนแปลงได้ในเวลาอยู่ตลอด (เช่น ค่าความผันผวนและอัตราดอกเบี้ย) จะช่วยให้โมเดลสามารถทำนายราคาออปชันในตลาดที่มีความผันผวนสูงอย่างคริปโทเคอร์เรนซ์ได้ดีและยืดหยุ่น
3. ได้แนวทางในการสร้างระบบทำนายราคาออปชันบิตคอยน์ล่วงหน้าที่สามารถปรับจูนตัวเองตามข้อมูลใหม่ๆ ได้ ซึ่งแสดงให้เห็นโอกาสในการนำไปใช้งานจริง
4. เป็นแนวทางให้นักลงทุนหรือที่ผู้สนใจนำโมเดลไปพัฒนาต่อยอดให้กลายเป็นเครื่องมือที่ช่วยตัดสินใจซื้อขายผลิตภัณฑ์ทางการเงินอื่น ๆ ที่มีความซับซ้อนและเปลี่ยนแปลงตลอดเวลาได้

บทที่ 2

วรรณกรรมและทฤษฎีที่เกี่ยวข้อง


กระบวนการสุ่มและการเคลื่อนที่แบบบราวน์

ระบบจำนวนมากในทางฟิสิกส์มีค่าที่เปลี่ยนแปลงในเวลาอยู่เสมอ ซึ่งไม่สามารถอธิบายได้ด้วยกฎเกณฑ์ที่ตายตัว แต่มีองค์ประกอบของการสุ่มเข้ามาเกี่ยวข้อง กระบวนการที่อธิบายการเปลี่ยนแปลงของระบบเหล่านี้ตามเวลาอย่างสุ่มเรียกว่า กระบวนการสุ่มแบบสโตแคสติก (Stochastic Process) ตัวอย่างที่เป็นรากฐานและสำคัญที่สุดในทางฟิสิกส์คือ การเคลื่อนที่แบบบราวน์ (Brownian Motion) ซึ่งเดิมใช้อธิบายการเคลื่อนที่อย่างสะเปะสะปะของอนุภาคนาโนเล็กที่แขวนลอยในของไหล เนื่องจากการถูกชนโดยโมเลกุลจำนวนมากของของไหลที่มีการเคลื่อนที่แบบสุ่มหลายทิศทางอย่างต่อเนื่องในเวลาและเป็นอิสระต่อกันและมีการแจกแจงแบบปกติ (Normal distribution)



ภาพ 2.1 การเคลื่อนที่อย่างสะเปะสะปะของอนุภาคนาโนเล็กจากจุดเริ่มต้นถึงจุดสุดท้าย

ที่มา. จาก *What is Brownian Motion?*, โดย ChemTalk, สืบค้นเมื่อ 30 กันยายน 2568, จาก <https://chemistrytalk.org/brownian-motion/>



ภาพ 2.2 ลักษณะเฉพาะของการแพร่ของอนุภาคบราวน์ ณ เวลาเริ่มต้น ($t=0$) โดยการกระจายตัวของอนุภาคจะมีลักษณะเป็นฟังก์ชันเดลตาของดิแรก (Dirac delta function) ซึ่งบ่งชี้ว่าอนุภาคทั้งหมดกระจุกตัวอยู่ที่จุดกำเนิดเพียงจุดเดียว เมื่อเวลา (t) เพิ่มขึ้น การกระจายตัวจะแผ่อกและแบนลง แต่ก็ยังคงรักษารูปร่างของเส้นโค้งรูประฆังไว้และในท้ายที่สุด การกระจายตัวของอนุภาคจะมีความสม่ำเสมอเมื่อเวลาเป็นค่าอนันต์


ที่มา. จาก wikipedia, โดย Bernard H. Lavenda, สืบค้นเมื่อ 30 กันยายน 2568, จาก https://commons.wikimedia.org/wiki/File:Diffusion_of_Brownian_particles.svg

ในโลกการเงิน แนวคิดนี้ถูกนำมาประยุกต์ใช้อย่างน่าทึ่ง ในปี 1900 หลุยส์ บาเชลลิเยร์ (Louis Bachelier) เกิดความคิดที่น่าสนใจและเสนอในวิทยานิพนธ์ของเขาว่าการเคลื่อนไหวของราคาหลักทรัพย์อาจมีลักษณะเป็นการเดินสุ่มแบบบราวน์เช่นกันแบบจำลองยุคแรกนี้เรียกว่าการเคลื่อนที่แบบบราวน์เชิงเลขคณิต Arithmetic Brownian Motion (ABM) ซึ่งมีรูปแบบสมการเชิงอนุพันธ์สุ่ม (Stochastic Differential Equation; SDE) ดังสมการ (1) [Bachelier, 1900]

$$dS_t = \mu S_t dt + \sigma S_t dW_t \quad (1)$$

โดยที่

- dS_t คือการเปลี่ยนแปลงเล็กน้อยของราคาสินทรัพย์ S ในช่วงเวลาสั้นๆ dt
- S_t คือราคาสินทรัพย์ ณ เวลา t
- μ คืออัตราผลตอบแทนคาดหวัง หรือ พจน์แนวนอน (Drift term)
- σ คือความผันผวนของราคา หรือขนาดของการสุ่ม
- dW_t คือส่วนองค์ประกอบของการสุ่มกระบวนการวีเนอร์ (Wiener Process)



ภาพ 2.3 ข้อมูลการจำลองเส้นทางสุ่ม (Simulated Paths) ของกระบวนการเคลื่อนที่แบบ Arithmetic Brownian Motion (ABM)

ที่มา. จาก *quantgirluk*, โดย Dialid Santiago, สืบค้นเมื่อ 3 พฤษภาคม 2568, จาก https://quantgirluk.github.io/Understanding-Quantitative-Finance/brownian_motion_arithmetic.html

อย่างไรก็ตาม แบบจำลอง ABM มีข้อบกพร่องเชิงทฤษฎีที่สำคัญคือการอนุญาตให้ราคาหลักทรัพย์สามารถ "ติดลบ" ได้ ซึ่งไม่สอดคล้องกับความเป็นจริงเพื่อแก้ปัญหานี้ พอล แซมมวลสัน (Paul Samuelson) ในช่วงทศวรรษ 1960 ได้เสนอให้ปรับปรุงแบบจำลองโดยมีสมมติฐานใหม่เพื่อให้พิจารณาราคาเป็นแบบเปอร์เซ็นต์แทน หรือการเปลี่ยนแปลงราคา ($\frac{dS_t}{S_t}$) ที่เป็นไปตามกระบวนการสุ่มไม่ใช่มูลค่าที่เปลี่ยนแปลง การปรับเปลี่ยนกระบวนการทศนี้นำไปสู่สมการที่เป็นหัวใจของแบบจำลองทางการเงินจำนวนมาก


นั่นคือการเคลื่อนที่แบบบราวน์เชิงเรขาคณิต (Geometric Brownian Motion; GBM) ซึ่งสามารถอธิบายได้ด้วยสมการเชิงอนุพันธ์สโตแคสติก (Stochastic Differential Equation; SDE) ดังนี้

$$\frac{dS_t}{S_t} = \mu dt + \sigma dW_t \quad (2)$$

หรือเขียนในรูปที่นิยมใช้ในปัจจุบัน

$$dS_t = \mu S_t dt + \sigma S_t dW_t \quad (3)$$

สมการ GBM นี้คือรากฐานทางคณิตศาสตร์ที่สำคัญที่สุดของแบบจำลองแบล็ก-โชลส์ โดยที่พจน์ $\mu S_t dt$ แสดงถึงผลตอบแทนที่คาดหวัง (Deterministic Drift) และพจน์ $\sigma S_t dW_t$ แสดงถึงองค์ประกอบของความเสี่ยงหรือความผันผวน (Stochastic Diffusion) ซึ่งเป็นพฤติกรรมที่สืบทอดโดยตรงมาจากหลักการการเคลื่อนที่แบบบราวเนียนในทางฟิสิกส์




ภาพ 2.4 ข้อมูลการจำลองเส้นทางสุ่ม (Simulated Paths) ของกระบวนการเคลื่อนที่แบบ GBM

ที่มา. จาก *quantgirluk*, โดย Dialid Santiago, สืบค้นเมื่อ 3 พฤษภาคม 2568, จาก https://quantgirluk.github.io/Understanding-Quantitative-Finance/geometric_Brownian_motion.html

สมการเชิงอนุพันธ์ย่อยในฟิสิกส์และเศรษฐฟิสิกส์

สมการเชิงอนุพันธ์ย่อย (Partial Differential Equations; PDEs) คือเครื่องมือทางคณิตศาสตร์ที่เป็นหัวใจสำคัญของฟิสิกส์ทฤษฎีซึ่งทำหน้าที่อธิบายการเปลี่ยนแปลงของระบบหรือสนามที่ขึ้นอยู่กับตัวแปรอิสระหลายตัวแปรพร้อมกันดังเช่น การเปลี่ยนแปลงเทียบกับทั้งเวลา (t) และตำแหน่งในปริภูมิ (x, y, z) สมการเหล่านี้เป็นรากฐานของทฤษฎีหลักทางฟิสิกส์ตั้งแต่สมการคลื่น สมการแมกซ์เวลล์ในทฤษฎีแม่-เหล็กไฟฟ้า สมการชเรอดิงเงอร์ในกลศาสตร์ควอนตัม ตลอดไปจนถึงสมการสนามของไอน์สไตน์ใน ทฤษฎีสัมพัทธภาพทั่วไป

ในบริบทที่เกี่ยวข้องโดยตรงกับกระบวนการสุ่ม (Stochastic Process) สมการ PDE ที่มีบทบาทสำคัญที่สุดก็คือ สมการการแพร่ (Diffusion Equation) หรือที่รู้จักกันในอีกชื่อหนึ่งว่า สมการความร้อน (Heat Equation) สมการการแพร่คือแบบจำลองในระดับมหภาคที่ใช้อธิบายพฤติกรรมโดยรวมของระบบที่ขับเคลื่อนโดยการเคลื่อนที่แบบสุ่มในระดับจุลภาค เราสามารถแสดงวิวัฒนาการของสมการนี้ได้จากการพิจารณากระบวนการเดินสุ่มแบบ 1 มิติ (1D Random Walk)



ภาพ 2.5 ข้อมูลการแจกแจงความน่าจะเป็น (Probability Distribution) ของตำแหน่งสุดท้าย (n) สำหรับกระบวนการเดินสุ่มแบบ 1 มิติ

ที่มา. จาก *galileo*, โดย Michael Fowler, สืบค้นเมื่อ 3 พฤษภาคม 2568, จาก <https://galileo.phys.virginia.edu/classes/152.mf1i.spring02/RandomWalk.htm>

สมมติให้ $P(x, t)$ คือความหนาแน่นของความน่าจะเป็น (Probability Density) ที่จะพบอนุภาค ณ ตำแหน่ง x ณ เวลา t ในช่วงเวลาสั้นๆ Δt อนุภาคจะเคลื่อนที่ไปทางซ้าย ($-\Delta x$) หรือทางขวา ($+\Delta x$) ด้วยโอกาส 50/50 ดังนั้นความน่าจะเป็น ณ เวลา $t + \Delta t$ จึงขึ้นอยู่กับความน่าจะเป็นในอดีต

$$P(x, t + \Delta t) = \frac{1}{2}P(x - \Delta x, t) + \frac{1}{2}P(x + \Delta x, t) \quad (4)$$

เมื่อเราทำการกระจายอนุกรมเทย์เลอร์ (Taylor Series Expansion) รอบจุด (x, t) โดยพิจารณาถึงเวลาอันดับที่หนึ่ง (Δt) และตำแหน่งอันดับที่สอง (Δx^2) (เนื่องจากการเคลื่อนที่แบบสุ่มมี $\Delta x \propto \sqrt{\Delta t}$) จะได้

$$P(x, t) + \frac{\partial P}{\partial t} \Delta t + \dots \approx \frac{1}{2} \left[P(x, t) - \frac{\partial P}{\partial x} \Delta x + \frac{1}{2} \frac{\partial^2 P}{\partial x^2} (\Delta x)^2 + \dots \right] + \frac{1}{2} \left[P(x, t) + \frac{\partial P}{\partial x} \Delta x + \frac{1}{2} \frac{\partial^2 P}{\partial x^2} (\Delta x)^2 + \dots \right] \quad (5)$$

หลังจากจัดรูปสมการโดยตัดพจน์ที่เหมือนกันออก จะได้

$$\frac{\partial P}{\partial t} \Delta t \approx \frac{1}{2} \frac{\partial^2 P}{\partial x^2} (\Delta x)^2 \quad (6)$$

จัดรูปใหม่จะได้

$$\frac{\partial P}{\partial t} \approx \left[\frac{(\Delta x)^2}{2\Delta t} \right] \frac{\partial^2 P}{\partial x^2} \quad (7)$$

ในลิมิตที่ $\Delta t \rightarrow 0$ และ $\Delta x \rightarrow 0$ โดยที่อัตราส่วน $\frac{(\Delta x)^2}{2\Delta t}$ เข้าสู่อค่าคงที่ค่าหนึ่ง ซึ่งเรานิยามว่าเป็น สัมประสิทธิ์การแพร่ (Diffusion Coefficient, D) [Einstein, 1905][Reif, 1965] เราจะได้สมการการแพร่ในรูปแบบมาตรฐาน

$$\frac{\partial P}{\partial t} = D \frac{\partial^2 P}{\partial x^2} \quad (8)$$

สมการนี้เป็นสมการเชิงอนุพันธ์ย่อยชนิดพาราโบลา (Parabolic PDE) ที่อธิบายการแพร่กระจายของอนุภาค (หรือการถ่ายเทความร้อน) จากบริเวณที่มีความเข้มข้นสูง (หรืออุณหภูมิ) ไปยังบริเวณที่มีความเข้มข้นต่ำ

แนวคิดของเศรษฐกิจฟิสิกส์ได้ถือกำเนิดขึ้นจากการตระหนักว่า ปรากฏการณ์ที่ซับซ้อนในระบบเศรษฐกิจและการเงิน โดยเฉพาะการเคลื่อนไหวของราคาหลักทรัพย์ก็มีลักษณะทางสถิติที่คล้ายคลึงกับการเคลื่อนที่ของอนุภาคในทางฟิสิกส์ หลุยส์ บาเชลลิเยร์ จึงได้เสนอสมการการแพร่นี้เพื่ออธิบายความน่าจะเป็นของราคาอปชันเอาไว้ตั้งแต่ปี 1900 [Bachelier, 1900]

การใช้ทฤษฎีบทของอิโต

ก่อนไปสู่แบบจำลองแบล็ก-โชลส์ จำเป็นต้องเข้าใจบทนิยามของอิโต Itô's Lemma ก่อน ซึ่งเป็นเครื่องมือทางคณิตศาสตร์ที่เป็นหัวใจสำคัญที่สุด และเป็นสะพานเชื่อมที่ขาดหายไประหว่างโลกของการสุ่ม (SDE) กับโลกของสมการที่แน่นอน (PDE) โดย คิโยชิ อิโต (Kiyosi Itô) คือนักคณิตศาสตร์ผู้พัฒนาแคลคูลัสใหม่ทั้งหมดเพื่อจัดการกับปัญหานี้ Itô's Lemma ก็คือ "Chain Rule" เวอร์ชันใหม่ที่ออกแบบมาสำหรับฟังก์ชันที่ขึ้นอยู่กับกระบวนการสุ่ม โดยเฉพาะ ตัวอย่างการสร้างสมการ (Derivation) สำหรับฟังก์ชัน $V(W_t, t)$ ที่ขึ้นอยู่กับ W_t (ตัวแปรที่เกิดการสุ่ม) และ t (เวลา) มีดังนี้

ขั้นที่ 1 ขยาย Taylor Series สำหรับ 2 ตัวแปรให้สมบูรณ์ โดยขยาย V ออกมาดูการเปลี่ยนแปลง ΔV โดยเก็บทุกพจน์ที่เกี่ยวข้องไว้ (ไม่ตัดอะไรทิ้งก่อน)

$$\Delta V \approx \frac{\partial V}{\partial t} \Delta t + \frac{\partial V}{\partial W} \Delta W_t + \frac{1}{2} \frac{\partial^2 V}{\partial t^2} (\Delta t)^2 + \frac{1}{2} \frac{\partial^2 V}{\partial W^2} (\Delta W_t)^2 + \frac{\partial^2 V}{\partial W \partial t} (\Delta W_t \Delta t) + \dots \quad (9)$$

ขั้นที่ 2 ใช้ "กฎ" ของ Itô โดยอิโตได้กำหนด "กฎการคูณ" แบบพิเศษสำหรับพจน์เล็กๆ (infinitesimal terms) เหล่านี้ โดยอิงจากคุณสมบัติทางสถิติมาตรฐานของ Brownian Motion ว่า $\Delta W_t \sim \sqrt{\Delta t}$ เมื่อให้ $\Delta t \rightarrow 0$ (เข้าสู่ลิมิตแบบต่อเนื่อง) กฎเหล่านี้คือ

- | | |
|----------------------------------|--|
| 1) $(dt)^2 \rightarrow 0$ | พจน์นี้เล็กเกินไป ถูกตัดทิ้งเหมือนแคลคูลัสปกติ |
| 2) $dt \cdot dW_t \rightarrow 0$ | พจน์นี้ก็เล็กเกินไปเช่นกัน |

3) $(dW_t)^2 \rightarrow dt$ กฎที่นี้บอกว่า "ความแปรปรวน" ของการสุ่ม คือ "เวลา" ขั้นที่ 3 แทนกฎใหม่ลงใน Taylor Series จากสมการที่ขยายไว้ในขั้นที่ 1 สมการ (9) และใช้ "กฎ" 3 ข้อนี้นี้ในรูปแบบ d (differential) แทน Δ (delta)

$$dV = \frac{\partial V}{\partial t} dt + \frac{\partial V}{\partial W} dW_t + \underbrace{\frac{1}{2} \frac{\partial^2 V}{\partial t^2} (dt)^2}_{\rightarrow 0} + \underbrace{\frac{1}{2} \frac{\partial^2 V}{\partial W^2} (dW_t)^2}_{=\frac{1}{2} \frac{\partial^2 V}{\partial W^2} dt} + \underbrace{\frac{\partial^2 V}{\partial W \partial t} (dW_t dt)}_{\rightarrow 0} + \dots \quad (10)$$

ขั้นที่ 4 จัดรูปสมการที่เหลือรอด หลังจากพจน์ส่วนใหญ่กลายเป็น 0

$$dV = \frac{\partial V}{\partial t} dt + \frac{\partial V}{\partial W} dW_t + \frac{1}{2} \frac{\partial^2 V}{\partial W^2} dt \quad (11)$$

จัดกลุ่มพจน์ dt (ส่วนที่คาดเดาได้) และ dW_t (ส่วนที่สุ่ม) ใหม่

$$dV = \left(\frac{\partial V}{\partial t} + \frac{1}{2} \frac{\partial^2 V}{\partial W^2} \right) dt + \left(\frac{\partial V}{\partial W} \right) dW_t \quad (12)$$

จากสมการ (12) พบว่ามี "พจน์พิเศษ" (Extra Term) ปรากฏ คือ $\frac{1}{2} \frac{\partial^2 V}{\partial W^2} dt$ พจน์นี้คือราคาที่ต้องจ่ายที่ V ไปยุ่งเกี่ยวกับกระบวนการสุ่ม

แบบจำลองแบล็ก-โชลส์

แบบจำลองแบล็ก-โชลส์ ซึ่งนำเสนอโดย ฟิชเชอร์ แบล็ก (Fischer Black) และ ไมรอน โชลส์ (Myron Scholes) ในปี 1973 และพัฒนาต่อโดย โรเบิร์ต เมอร์ตัน (Robert Merton) ถือเป็นแบบจำลองทางคณิตศาสตร์ที่เป็นรากฐานและปฏิวัติวงการวิศวกรรมการเงินแบบจำลองนี้ให้วิธีการเชิงปริมาณในการประเมินราคาอนุพันธ์ทางการเงินประเภท European Option โดยสร้างความเชื่อมโยงที่ลึกซึ้งระหว่างทฤษฎีความน่าจะเป็นทางการเงินและสมการเชิงอนุพันธ์ย่อยในทางฟิสิกส์ จุดเริ่มต้นของแบบจำลองแบล็ก-โชลส์ ตั้งอยู่บนสมมติฐานหลักที่ว่า ราคาของสินทรัพย์อ้างอิง (S) มีการเคลื่อนที่ตามกระบวนการ Geometric Brownian Motion (GBM) ซึ่งเป็นสมการเชิงอนุพันธ์สุ่ม (SDE) ตามสมการที่ 3 ดังนี้

$$dS_t = \mu S_t dt + \sigma S_t dW_t \quad \text{จากสมการ (3)}$$

โดยที่ μ คืออัตราผลตอบแทนคาดหวัง σ คือความผันผวน และ dW_t คือส่วนเพิ่มของกระบวนการวิเนอร์เป้าหมายคือต้องการหาสมการที่อธิบายการเปลี่ยนแปลงของราคาออปชัน (V) ซึ่งไม่รู้ค่าล่วงหน้า แต่รู้ว่า V ขึ้นอยู่กับราคาหุ้น (S) และเวลา (t) หรือ $V = V(S, t)$ โดยมีเครื่องมือ (สมมติฐาน) 3 อย่างได้แก่

1. การเคลื่อนที่ของ S (ราคาหุ้น) แบบ GBM
2. Itô's Lemma
3. ตรรกะการเงินแบบ No-Arbitrage (การไม่เก็งกำไร) ซึ่งบังคับให้พอร์ตที่ปราศจากความเสี่ยงต้องให้ผลตอบแทนเท่ากับอัตราดอกเบี้ย (r)

ขั้นที่ 1 การใช้ Itô's Lemma หา dV จาก $V(S, t)$ โดยมองว่า S เป็นกระบวนการสุ่ม (SDE) เริ่มต้นด้วยการกระจายอนุกรมเทย์เลอร์ (Taylor Expansion) สำหรับ $V(S, t)$ แบบสองตัวแปรโดยมีวิธีทำคล้ายกับหัวข้อ การใช้บทนิยามเลมมาของอิโต (Ito's Lemma) เขียนได้ดังนี้

$$\Delta V \approx \frac{\partial V}{\partial t} \Delta t + \frac{\partial V}{\partial S} \Delta S + \frac{1}{2} \frac{\partial^2 V}{\partial t^2} (\Delta t)^2 + \frac{1}{2} \frac{\partial^2 V}{\partial S^2} (\Delta S)^2 + \frac{\partial^2 V}{\partial S \partial t} (\Delta S \Delta t) + \dots \quad (13)$$

ใช้ "กฎการคูณของอิโต" (Itô's multiplication rules) ซึ่งเป็นผลมาจากคุณสมบัติ $\Delta W_t \sim \sqrt{\Delta t}$ เมื่อเราพิจารณาขีดจำกัด $\Delta t \rightarrow 0$ (หรือเขียนในรูป d)

1. $dt \cdot dt = 0$
2. $dt \cdot dW_t = 0$
3. $dW_t \cdot dW_t = dt$ (นี่คือกฎที่สำคัญที่สุด)

จำเป็นต้องรู้ว่าพจน์ $(\Delta S)^2$ และ $(\Delta S \Delta t)$ มีค่าเท่าใดในโลกของอิโตหาค่า $(dS)^2$ โดยนำสมการ (3) ยกกำลังสอง

$$\begin{aligned} (dS)^2 &= (\mu S dt + \sigma S dW_t)^2 \\ (dS)^2 &= \underbrace{(\mu S)^2 (dt)^2}_{\rightarrow 0} + \underbrace{2\mu\sigma S^2 (dt dW_t)}_{\rightarrow 0} + \underbrace{(\sigma S)^2 (dW_t)^2}_{\rightarrow (\sigma S)^2 dt} \\ (dS)^2 &= \sigma^2 S^2 dt \quad (\text{มีเพียงพจน์เดียวที่รอด}) \end{aligned} \quad (14)$$

ต่อไปหา $(dS \cdot dt)$

$$\begin{aligned}(dS \cdot dt) &= (\mu S dt + \sigma S dW_t) \cdot dt \\(dS \cdot dt) &= \underbrace{\mu S (dt)^2}_{\rightarrow 0} + \underbrace{\sigma S (dW_t dt)}_{\rightarrow 0} \\(dS \cdot dt) &= 0\end{aligned}\tag{15}$$

เมื่อเรานำ "กฎ" เหล่านี้ (รวมถึง $(dt)^2 = 0$) กลับไปแทนใน Taylor Expansion จะเหลือพจน์ที่ "รอด" เพียง 3 พจน์คือ

$$dV = \frac{\partial V}{\partial t} dt + \frac{\partial V}{\partial S} dS + \frac{1}{2} \frac{\partial^2 V}{\partial S^2} (dS)^2\tag{16}$$

แทนที่ dS จากสมการ (3) และ $(dS)^2$ จากสมการ (14) ลงในสมการ (16)

$$dV = \frac{\partial V}{\partial t} dt + \frac{\partial V}{\partial S} (\mu S dt + \sigma S dW_t) + \frac{1}{2} \frac{\partial^2 V}{\partial S^2} (\sigma^2 S^2 dt)\tag{17}$$

จัดกลุ่มพจน์ dt (ส่วนที่คาดเดาได้) และ dW_t (ส่วนที่สุ่ม)

$$dV = \left(\frac{\partial V}{\partial t} + \mu S \frac{\partial V}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt + \left(\sigma S \frac{\partial V}{\partial S} \right) dW_t\tag{18}$$

นี่คือ SDE สำหรับราคาอปชัน V ซึ่งยังคง "สุ่ม" อยู่เพราะมี dW_t

ขั้นที่ 2 สร้างพอร์ต (กำจัด dW_t) ด้วยการสร้างพอร์ต Π (Pi) ที่ประกอบด้วย

1. ถืออปชัน 1 หน่วย (มูลค่า $+ V$)
2. ขาย (Short) หุ้น Δ (Delta) หน่วย (มูลค่า $-\Delta S$)

มูลค่าพอร์ต $\Pi = V - \Delta S$ การเปลี่ยนแปลงของพอร์ตคือ

$$d\Pi = dV - \Delta dS\tag{19}$$

แทนค่า dV จากสมการ (18) และ dS จากสมการ (3) ลงในสมการ (19)

$$d\Pi = \left[\left(\frac{\partial V}{\partial t} + \mu S \frac{\partial V}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt + \left(\sigma S \frac{\partial V}{\partial S} \right) dW_t \right] - \Delta [\mu S dt + \sigma S dW_t]\tag{20}$$

จัดกลุ่มพจน์ dt และ dW_t ใหม่

$$d\Pi = \left(\frac{\partial V}{\partial t} + \mu S \frac{\partial V}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} - \Delta \mu S \right) dt + \left(\sigma S \frac{\partial V}{\partial S} - \Delta \sigma S \right) dW_t\tag{21}$$

การจัดการสุ่มทั้งหมด (dW_t) โดยเลือก Δ ให้พจน์ที่คูณ dW_t เป็นศูนย์

$$\sigma S \frac{\partial V}{\partial S} - \Delta \sigma S = 0 \rightarrow \Delta = \frac{\partial V}{\partial S} \quad (22)$$

นี่คือ "Delta Hedging" ถ้าอยากปรับพอร์ตตลอดเวลาต้องถือหุ้นจำนวน $\Delta = \frac{\partial V}{\partial S}$ หน่วยพอร์ตจึงจะ "ปราศจากความเสี่ยง" โดยสมบูรณ์

ขั้นตอนที่ 3 ประกอบ PDE เมื่อตั้ง $\Delta = \frac{\partial V}{\partial S}$ พจน์ dW_t ทั้งหมดจะหายไป (กลายเป็น 0) สมการ $d\Pi$ ก็จะเหลือแค่ส่วน dt

$$d\Pi = \left(\frac{\partial V}{\partial t} + \mu S \frac{\partial V}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} - \left(\frac{\partial V}{\partial S} \right) \mu S \right) dt \quad (23)$$

สังเกตว่าพจน์ $\mu S \frac{\partial V}{\partial S}$ หักล้างกันเองพอดี

$$d\Pi = \left(\frac{\partial V}{\partial t} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt \quad (24)$$

นี่คือสมการสำหรับการเปลี่ยนแปลงของพอร์ตที่ "ปราศจากความเสี่ยง" แต่จากตรรกะการเงิน (No-Arbitrage) พบว่า "พอร์ตที่ปราศจากความเสี่ยง" จะต้องให้ผลตอบแทนเท่ากับ "อัตราดอกเบี้ยที่ปราศจากความเสี่ยง (r)"

$$d\Pi = r \Pi dt \quad (25)$$

แทนค่า $\Pi = V - \Delta S = V - \frac{\partial V}{\partial S} S$ ลงไป

$$\begin{aligned} d\Pi &= r \left(V - \frac{\partial V}{\partial S} S \right) dt \\ d\Pi &= \left(rV - rS \frac{\partial V}{\partial S} \right) dt \end{aligned} \quad (26)$$

ในเมื่อทั้งสมการ (24) และสมการ (26) อธิบายสิ่งเดียวกัน ($d\Pi$) จึงต้องเท่ากัน

$$\left(\frac{\partial V}{\partial t} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt = \left(rV - rS \frac{\partial V}{\partial S} \right) dt \quad (27)$$

ตัด dt ทั้งสองข้าง

$$\frac{\partial V}{\partial t} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} = rV - rS \frac{\partial V}{\partial S} \quad (28)$$

สุดท้าย ย้ายทุกอย่างมาฝั่งเดียวกันเพื่อให้เท่ากับ 0

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0 \quad (29)$$

นี่คือสมการ Black-Scholes PDE ที่เป็นผลลัพธ์ของการรวม SDE, Itô's Lemma, และตรรกะ No-Arbitrage เข้าด้วยกันอย่างสมบูรณ์ และยังสามารถจัดองค์ประกอบของการสุ่ม (dW_t) ออกไปได้ และผลลัพธ์ที่ได้คือสมการเชิงอนุพันธ์ย่อยแบบกำหนดได้ (Deterministic PDE) [Black & Scholes, 1973; Merton, 1973][Hull (2015)]

ภายใต้ข้อสมมติฐานเหล่านี้ โดยเฉพาะอย่างยิ่งการที่ σ และ r เป็นค่าคงที่ ทำให้สมการ PDE (29) กลายเป็นสมการเชิงเส้น (Linear PDE) ที่มีสัมประสิทธิ์คงที่ ซึ่งสามารถหา ผลเฉลยเชิงวิเคราะห์ (Analytical Solution) ที่แน่นอนได้ สำหรับ European Call Option (C) ผลเฉลยดังกล่าวคือ สูตรของแบล็ก-โชลส์ (Black-Scholes Formula) ที่มีชื่อเสียง

$$C(S, t) = S \cdot N(d_1) - K \cdot e^{-r(T-t)} \cdot N(d_2) \quad (30)$$

โดยที่ $N(\cdot)$ คือฟังก์ชันการแจกแจงความน่าจะเป็นปกติสะสม (Cumulative Normal Distribution Function) และ

$$d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)(T-t)}{\sigma\sqrt{T-t}} \quad (31)$$

$$d_2 = d_1 - \sigma\sqrt{T-t} \quad (32)$$

ผลเฉลยนี้ถือเป็นเกณฑ์มาตรฐาน (Benchmark) ที่ใช้ในการเปรียบเทียบกับแบบจำลองอื่น ๆ ทั้งหมด อย่างไรก็ตามความแม่นยำของผลเฉลยนี้ขึ้นอยู่กับความถูกต้องของข้อสมมติฐานที่ใช้ด้วย

โครงข่ายประสาทเทียม

โครงข่ายประสาทเทียมแบบป้อนไปข้างหน้า (Feedforward Neural Network) หรือ Multi-Layer Perceptron (MLP) ประกอบด้วยนิวรอน (Neuron) หรือ โหนด (Node) ที่จัดเรียงกันเป็นชั้น ๆ (Layers) ได้แก่ ชั้นอินพุต (Input Layer) ชั้นซ่อน (Hidden Layers) อย่างน้อยหนึ่งชั้น และชั้นเอาต์พุต (Output Layer) การคำนวณของนิวรอนหนึ่งตัวในชั้นซ่อนสามารถอธิบายได้ด้วยสมการทางคณิตศาสตร์ดังนี้

$$y = \phi(\sum_{i=1}^N w_i x_i + b) \quad (33)$$


โดยที่

x_i คือสัญญาณอินพุตจากชั้นก่อนหน้า

w_i คือค่าน้ำหนัก (Weight) ของแต่ละโหนด ซึ่งเป็นพารามิเตอร์ที่ปรับค่าได้

b คือค่าไบแอส (Bias) ซึ่งเป็นพารามิเตอร์ที่ปรับค่าได้

$\phi(\cdot)$ คือฟังก์ชันกระตุ้น (Activation Function) ที่มีคุณสมบัติไม่เป็นเชิงเส้น เช่น ฟังก์ชัน Sigmoid, Tanh หรืออื่นๆ



ภาพ 2.6 สถาปัตยกรรมโครงข่ายประสาทเทียมแบบ MLP (ส่วน-บน) และกลไกการคำนวณของนิวรอนเดี่ยว (ส่วนล่าง)

ที่มา. จาก *ResearchGate*, โดย Miguel Pérez-Enciso, สืบค้นเมื่อ 9 พฤษภาคม 2568, จาก https://www.researchgate.net/figure/Multi-Layer-Perceptron-MLP-diagram-withfour-hidden-layers-and-a-collection-of-single_fig1_334609713

เครือข่ายทั้งหมดคือการนำฟังก์ชันง่ายๆ เหล่านี้มาประกอบกันเป็น ฟังก์ชันผสม (Composite Function) ที่ซับซ้อนมหาศาล $V_{NN}(x; \theta)$ โดยที่ x คือเวกเตอร์อินพุต และ θ (theta) คือเซตของพารามิเตอร์ (ค่าน้ำหนักและไบแอส) ทั้งหมดในเครือข่าย เหตุผลที่โครงข่ายประสาทเทียมถูกนำมาใช้เป็นเครื่องมือแก้ปัญหาเชิงคำนวณนั้นมีรากฐานมาจากทฤษฎีบทที่สำคัญอย่างยิ่ง นั่นคือทฤษฎีบทการประมาณค่าสากล (Universal Approximation Theorem) ทฤษฎีบทนี้ (ซึ่งถูกพิสูจน์โดย Cybenko (1989) และ Hornik et al. (1989)) ระบุว่า โครงข่ายประสาทเทียมแบบป้อนไปข้างหน้าที่มีเพียง ชั้นซ่อนเดียว แต่มีจำนวนนิวรอนในชั้นนั้นมากพอ ก็สามารถใช้ฟังก์ชันกระตุ้นที่ไม่เป็นเชิงเส้น (เช่น Sigmoid) เพื่อประมาณค่าฟังก์ชันต่อเนื่องใดๆ $f(x)$ ได้อย่างแม่นยำได้

$$|V_{NN}(x; \theta) - f(x)| < \epsilon \quad \text{for all } x \quad (34)$$

ทฤษฎีบทนี้มีความหมายที่ลึกซึ้งอย่างยิ่งต่องานวิจัยนี้

1. ผลเฉลย PDE คือฟังก์ชัน "ผลเฉลย" ที่เรากำลังค้นหาสำหรับสมการแบล็ก-โชลส์ PDE ก็คือฟังก์ชันต่อเนื่อง $V(S, t)$
2. NNs สามารถเป็นผลเฉลยได้ โครงข่ายประสาทเทียม $V_{NN}(S, t; \theta)$ สามารถ "เลียนแบบ" หรือ "ประมาณค่า" ผลเฉลย $V(S, t)$ ที่แท้จริงได้
3. เปลี่ยนกระบวนการทัศนจากการแก้สมการเชิงอนุพันธ์ย่อย ซึ่งอาจเป็นไปได้ในทางวิเคราะห์ ไปสู่ปัญหาการปรับค่าพารามิเตอร์ (Optimization Problem) กล่าวคือ เราไม่ได้พยายามหา $V(S, t)$ โดยตรง แต่เราพยายาม "ค้นหา" ชุดพารามิเตอร์ θ ที่ดีที่สุดที่ทำให้ค่าประมาณ $V_{NN}(S, t; \theta)$ ของเรา สอดคล้องกับ "กฎทางฟิสิกส์" (คือสมการ PDE) ให้ได้มากที่สุด คุณสมบัติการประมาณค่าสากลนี้ จึงเป็นเสาหลักที่ทำให้แนวคิดโครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์เป็นไปได้ ซึ่งจะนำไปสู่ความสามารถในการคำนวณอนุพันธ์ของ V_{NN} เทียบกับอินพุต S และ t เพื่อบังคับใช้กฎทางฟิสิกส์

การหาอนุพันธ์เชิงอัตโนมัติ

คุณสมบัติการประมาณค่าฟังก์ชันสากล เป็นการรับประกันทางทฤษฎีว่า โครงข่ายประสาทเทียม $V_{NN}(x; \theta)$ สามารถ "เป็น" ผลเฉลยของสมการ PDE ได้อย่างไรก็ตาม เพื่อบังคับให้โครงข่ายประสาทเทียมนี้สอดคล้องกับกฎทางฟิสิกส์ (เช่น สมการแบล็ก-โฮลส์ PDE) เราจำเป็นต้องสามารถคำนวณ "ส่วนเหลือ" (Residual) ของสมการ PDE นั้นได้ ยกตัวอย่างเช่น ในการแก้สมการแบล็ก-โฮลส์ เราจำเป็นต้องคำนวณค่าอนุพันธ์ย่อยของผลลัพธ์ V_{NN} เทียบกับอินพุต S และ t อันได้แก่พจน์ $\frac{\partial V_{NN}}{\partial t}$, $\frac{\partial V_{NN}}{\partial S}$ และ $\frac{\partial^2 V_{NN}}{\partial S^2}$ ในระเบียบวิธีเชิงตัวเลขแบบดั้งเดิม (Traditional Numerical Methods) ทางฟิสิกส์ นักคำนวณมักใช้การประมาณค่าอนุพันธ์เชิงตัวเลข (Numerical Differentiation) เช่น วิธีผลต่างจำกัด (Finite Difference Method)

$$\frac{\partial V}{\partial S} \approx \frac{V(S+\epsilon, t) - V(S-\epsilon, t)}{2\epsilon} \quad (35)$$


แม้ว่าวิธีนี้จะรวดเร็วแต่ก็มีข้อบกพร่องร้ายแรงคือเป็นเพียง “ค่าประมาณ” ที่มีความคลาด (จากการละเลยพจน์อันดับสูงในอนุกรมเทย์เลอร์) และความคลาดเคลื่อนจากการปัดเศษ (Rounding Error) จากความแม่นยำของคอมพิวเตอร์ การใช้ค่าอนุพันธ์โดยประมาณนี้ในการฝึกสอนโมเดล Deep Learning ซึ่งต้องอาศัยการไล่ระดับ (Gradient Descent) ที่แม่นยำ มักนำไปสู่ความไร้เสถียรภาพและความล้มเหลวในการหาคำตอบ จุดเปลี่ยนที่ทำให้ PINNs เป็นไปได้ คือเทคโนโลยีที่เรียกว่า การหาอนุพันธ์เชิงอัตโนมัติ (Automatic Differentiation; AD) ซึ่งเป็นกลไกหลักที่ฝังอยู่ในเฟรมเวิร์ก Deep Learning สมัยใหม่ (เช่น PyTorch หรือ TensorFlow) AD ไม่ใช้การหาอนุพันธ์เชิงสัญลักษณ์ (Symbolic Differentiation) (แบบที่โปรแกรม Mathematica ทำ) และไม่ใช้การหาอนุพันธ์เชิงตัวเลข (Numerical Differentiation) (แบบ Finite Difference) แต่ AD เป็นเทคนิคเชิงคำนวณที่ให้ ค่าอนุพันธ์ที่แม่นยำถึงระดับความละเอียดของเครื่อง (Machine Precision) โดยการประยุกต์ใช้ กฎลูกโซ่ (Chain Rule) ในทางแคลคูลัสอย่างเป็นระบบ

ในทางปฏิบัติ โครงข่ายประสาทเทียม V_{NN} คือฟังก์ชันผสมที่ซับซ้อนมหาศาลซึ่งเกิดจากการนำการดำเนินการเชิงเส้นและฟังก์ชันกระตุ้นที่ไม่เป็นเชิงเส้น มาประกอบกันนับล้านครั้ง โดยเฟรมเวิร์ก AD จะสร้างการคำนวณเชิงกราฟ (Computational Graph) ของฟังก์ชันผสมนี้ไว้ในหน่วยความจำ

เมื่อเราต้องการหาอนุพันธ์ของเอาต์พุตเทียบกับอินพุต (เช่น $\frac{\partial V_{NN}}{\partial s}$) AD จะทำการคำนวณย้อนกลับ (Backward Pass) ผ่านกราฟนี้โดยใช้กฎลูกโซ่อย่างเป็นลำดับขั้นเพื่อสะสมค่าอนุพันธ์จากชั้นเอาต์พุตกลับมายังชั้นอินพุต กระบวนการนี้มักรู้จักกันในชื่อ "การแพร่ย้อนกลับ" Backpropagation ซึ่งเดิมทีถูกใช้เพื่อหาอนุพันธ์ของฟังก์ชันความสูญเสีย (Loss) เทียบกับ "ค่าน้ำหนัก" ($\frac{\partial L}{\partial \theta}$) เพื่อใช้ในการ "ฝึกสอน" โมเดล [Rumelhart et al., 1986] แนวคิดหลักของ PINNs คือการ "ประยุกต์ใช้" กลไก AD นี้ซ้ำเป็นครั้งที่สอง แต่แทนที่จะหาอนุพันธ์เทียบกับค่าน้ำหนัก เรากลับใช้เพื่อหาอนุพันธ์เทียบกับ "อินพุต" สิ่งนี้ทำให้เราสามารถคำนวณพจน์ต่าง ๆ ในสมการ PDE ได้

สถาปัตยกรรมและฟังก์ชันความสูญเสียเชิงฟิสิกส์

โครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์ (PINNs) ถูกนำเสนอและพัฒนาอย่างก้าวกระโดดโดย Raissi, Perdikaris, และ Karniadakis (2019) PINNs ไม่ได้เรียนรู้จากข้อมูลดิบเพียงอย่างเดียว แต่เรียนรู้จากสมการเชิงอนุพันธ์ย่อยที่ควบคุมปรากฏการณ์นั้นๆ ด้วย



ภาพ 2.7 กรอบแนวคิดเชิงสถาปัตยกรรมและกระบวนการคำนวณของโครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงฟิสิกส์ (Physics-Informed Neural Networks; PINNs)

ที่มา. จาก *medium*, โดย Oluwafemidiakhoa, สืบค้นเมื่อ 9 พฤษภาคม 2568, จาก <https://medium.com/kinomoto-mag/exploring-the-capabilities-of-physics-informed-neural-networks-pinns-integrating-data-science-a2e11fc31e19>

สถาปัตยกรรมหลักของ PINN ที่ใช้ในการแก้ปัญหา Black-Scholes PDE โดยทั่วไปคือโครงข่ายประสาทเทียมแบบป้อนไปข้างหน้า (Feedforward Neural Network) หรือ Multi-Layer Perceptron (MLP) ส่วนสำคัญของ PINNs คือการออกแบบฟังก์ชันความสูญเสีย (Loss Function) ซึ่งไม่ได้เปรียบเทียบแค่ "คำตอบ" กับ "ข้อมูล" เพียงอย่างเดียว แต่ยังเปรียบเทียบ "พฤติกรรม" ของโมเดลกับ "กฎทางฟิสิกส์" ด้วย ฟังก์ชันความสูญเสียรวมประกอบด้วยสององค์ประกอบหลัก ดังที่ปรากฏในงานวิจัยอ้างอิง (Dhiman & Hu, 2023) และการใช้งานจริงในโค้ดของงานวิจัยนี้

$$\mathcal{L}_{total}(\theta) = \mathcal{L}_{data} + \lambda \mathcal{L}_{physics} \quad (36)$$

โดยที่ λ คือค่าน้ำหนัก (Weighting Factor) ที่ใช้ปรับสมดุลระหว่าง Loss ทั้งสองส่วนคือ

1. Data Loss หรือ Boundary Loss ส่วนนี้คือการเรียนรู้แบบมีผู้สอน (Supervised Learning) แบบดั้งเดิม โดยเป็นการบังคับให้ผลเฉลย V_{NN} ต้องมีค่าตรงกับ "เงื่อนไข

ขอบเขต" (Boundary Conditions) และ "เงื่อนไขเริ่มต้น" (Initial Condition) ที่ทราบค่าอยู่แล้ว ในบริบทของ Black-Scholes European Call Option (ดังที่แสดงในโค้ด `usdt_call_pricing_mlp.py`) คือผลรวมของ Mean Squared Error (MSE) ของเงื่อนไข 3 ส่วนดังนี้

เงื่อนไขเริ่มต้น (Initial Value Problem; IVP) คือผลตอบแทนที่ $t = T$

$$\mathcal{L}_{IVP} = \text{MSE}(V_{\text{NN}}(S, T), \max(S - K, 0)) \quad (37)$$

เงื่อนไขขอบเขต (Boundary Value Problem; BVP) เมื่อ $S = S_{\min}$ (เช่น $S = 0$) ออปชันจะไร้มูลค่า

$$\mathcal{L}_{BVP_1} = \text{MSE}(V_{\text{NN}}(S_{\min}, t), 0) \quad (38)$$

เมื่อ $S = S_{\max}$ (ราคาสูงมาก) ออปชันจะมีค่าใกล้เคียงกับการถือหุ้นที่มูลค่าสูงนั้น

$$\mathcal{L}_{BVP_2} = \text{MSE}(V_{\text{NN}}(S_{\max}, t), S_{\max} - Ke^{-r(T-t)}) \quad (39)$$

เมื่อเรารวม Mean Squared Error (MSE) ของเงื่อนไข 3 ส่วนเข้าด้วยกันก็จะได้ว่า

$$\mathcal{L}_{\text{data}} = \mathcal{L}_{IVP} + \mathcal{L}_{BVP_1} + \mathcal{L}_{BVP_2} \quad (40)$$

2. Physics Loss หรือ PDE Residual Loss นี่คือน้องประกอบที่ทรงพลังที่สุดและเป็นนวัตกรรมหลักของ PINNs คือการเรียนรู้แบบไม่มีผู้สอน โดยเป็นการบังคับให้ผลเฉลย V_{NN} ต้อง "ปฏิบัติตาม" กฎทางฟิสิกส์ (Black-Scholes PDE) ในทุกจุด (S, t) ภายในโดเมน (เรียกว่า Collocation Points) เรานิยาม "ส่วนเหลือเชิงฟิสิกส์" (Physics Residual, $\mathcal{F}$) โดยการย้ายข้างสมการ PDE (สมการที่ 29) ให้เท่ากับศูนย์

$$\mathcal{F}[V] \equiv \frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0 \quad (41)$$

จากนั้นใช้ไลบรารี Automatic Differentiation (AD) เพื่อคำนวณอนุพันธ์ย่อย $\frac{\partial V_{\text{NN}}}{\partial t}$, $\frac{\partial V_{\text{NN}}}{\partial S}$ และ $\frac{\partial^2 V_{\text{NN}}}{\partial S^2}$ จากผลลัพธ์ของโครงข่ายประสาทเทียมโดยตรง จากนั้นนำอนุพันธ์ที่คำนวณได้เหล่านี้ไปแทนค่าใน $\mathcal{F}$ เพื่อหา "ส่วนเหลือ" ของสมการ PDE

$$\mathcal{L}_{physics} = \text{MSE}(\mathcal{F}[V_{\text{NN}}(S, t)], 0) \quad (42)$$

หาก $\mathcal{L}_{physics}$ มีค่าเข้าใกล้ 0 ก็หมายความว่าโครงข่ายประสาทเทียม V_{NN} ได้เรียนรู้ที่จะแก้สมการ Black-Scholes PDE ได้สำเร็จ โดยสรุป กระบวนการ Optimization คือการค้นหาชุดพารามิเตอร์ θ ที่ดีที่สุด ที่ทำให้ V_{NN} สามารถสอดคล้องกับทั้งข้อมูลจริงที่ขอบเขต (Data Loss) และสมการเชิงอนุพันธ์ที่ควบคุมระบบ (Physics Loss) ได้พร้อมกัน

บทที่ 3

วิธีดำเนินการวิจัย

เครื่องมือที่ใช้ในการวิจัย

1. การดำเนินการวิจัยทั้งหมดถูกเขียนขึ้นด้วยภาษา ภาษาไพทอน (Python) เนื่องจากระบบนิเวศ (Ecosystem) ของไลบรารีที่ให้ใช้ฟรีและหลากหลาย
2. ไลบรารี PyTorch เป็นชุดคำสั่งหลักที่ใช้ในการสร้างและฝึกสอนโครงข่ายประสาทเทียมทั้งหมด รวมถึงการหาผลเฉลี่ยของอนุพันธ์เชิงอัตโนมัติ
3. ไลบรารี Pandas เป็นชุดคำสั่งการจัดการข้อมูลไฟล์ .csv โดยทำหน้าที่อ่านไฟล์ จัดการข้อมูลอนุกรมเวลา และแปลงค่าตัวแปร
4. ไลบรารี Matplotlib ใช้สร้างกราฟเพื่อวิเคราะห์การเปลี่ยนแปลงของข้อมูล
5. คอมพิวเตอร์ใช้สำหรับประมวลผลอัลกอริทึม PINN และจัดเก็บข้อมูล

ข้อมูลการวิจัย

1. สถาปัตยกรรม PINN ที่ใช้สำหรับ BSPDEM ได้จากงานวิจัย Physics Informed Neural Network for Option Pricing โดย Ashish Dhiman และ Yibei Hu (https://github.com/ashish1610dhiman/pinn_option_pricing)
2. ข้อมูลอปชันบิตคอยน์จาก Binance API ได้แก่ เวลา (t) ราคาอปชันบิตคอยน์ (V) ราคาใช้สิทธิ (K) และประเภทวันหมดอายุ (T)



ภาพ 3.1 ตัวอย่างกราฟแท่งเทียน (Candlestick Chart) ของอปชันบิตคอยน์บนแพลตฟอร์ม Binance

ที่มา. จาก *binance*, โดย BINANCE OPTIONS, สืบค้นเมื่อ 16 พฤศจิกายน 2568, จาก <https://www.binance.com/en/eoptions>

ภาพ 3.1 แสดงกราฟแท่งเทียนของอปชันบิตคอยน์ของสัญญา BTC-251121-96000-C บนแพลตฟอร์ม Binance โดย BTC หมายถึงสินทรัพย์อ้างอิง 251121 คือวันหมดอายุ 96000 คือราคาใช้สิทธิ (K) และ C คือการระบุประเภทอปชันเป็น Call โดยแต่ละแท่งเทียนจะสรุปข้อมูลราคาในกรอบเวลา 1 ชั่วโมง ซึ่งประกอบด้วย ราคาเปิด (Open) ราคาสูงสุด (High) ราคาต่ำสุด (Low) และราคาปิด (Close) ของราคาอปชัน (V) โดยแท่งสีเขียวหมายถึงราคาปิดสูงกว่าราคาเปิด และแท่งสีแดงหมายถึงราคาปิดต่ำกว่าราคาเปิด ราคาอปชัน (V) นี้จะผันผวนตามปัจจัยต่าง ๆ ตามเวลา

Estimated PnL Chart	K-line	Info	▼
Price Source	BTCUSDT Price Index		
Contract Size	1BTC		
Expiry Date	2025-11-21 15:00:00		
Expiration Type	Weekly		
Settlement Currency	USDT		
Min Order Size	0.01 Contracts		
Max Order Size	200 Contracts		
Position Limit	View More		
Tick Size	5		
Max Buy Price	19,226.9		
Min Sell Price	5.0		

ภาพ 3.2 ข้อมูลสัญญาปิดคอยน์อปชันบนแพลตฟอร์ม Binance ของสัญญาในภาพ 3.1

ที่มา. จาก *binance*, โดย BINANCE OPTIONS, สืบค้นเมื่อ 16 พฤศจิกายน 2568, จาก <https://www.binance.com/en/eoptions>

ภาพ 3.2 แสดงข้อมูลของสัญญาอปชันปิดคอยน์ บนแพลตฟอร์ม Binance ซึ่งให้รายละเอียดสำคัญของสัญญาที่ใช้ในการคำนวณตามโมเดล Black-Scholes ได้แก่ ราคาสินทรัพย์อ้างอิง BTCUSDT Price Index วันหมดอายุ (Expiry Date) และประเภทวันหมดอายุ (Expiration Type) ข้อมูลเหล่านี้สำคัญต่อการกำหนดราคาปิดคอยน์ S และเวลาหมดอายุ T เพื่อใช้ในการฝึก PINN

3. ข้อมูลบิตคอยน์ได้รับจาก Binance API ได้แก่ เวลา (t) และราคาบิตคอยน์ (S)



ภาพ 3.3 ตัวอย่างกราฟแท่งเทียนของราคาบิตคอยน์บนแพลตฟอร์ม Binance

ที่มา. จาก *binance*, โดย BINANCE OPTIONS, สืบค้นเมื่อ 16 พฤศจิกายน 2568, จาก <https://www.binance.com/en/eoptions>

ภาพ 3.3 แสดงกราฟแท่งเทียน (Candlestick Chart) ของราคาบิตคอยน์ (BTC USD) บนแพลตฟอร์ม Binance ข้อมูลมีความแตกต่างจากภาพ 3.2 (ราคาอปชัน) กราฟแสดงราคาหลักทรัพย์อ้างอิง แต่ละแท่งเทียนประกอบด้วยข้อมูล ราคาเปิด ราคาสูงสุด ราคาต่ำสุด และราคาปิด ในกรอบเวลา 1 ชั่วโมง แกน Y คือราคาบิตคอยน์จริง ซึ่งเป็นอินพุตที่สำคัญและส่งผลโดยตรงต่อการเคลื่อนไหวของราคาอปชัน

วิธีการทำการวิจัย

1. พัฒนา PINN แบบ 1) เพื่อฝึกและทดสอบแบบจำลอง "PINN Model A" ชนิด อินพุต 2 ตัวแปร ข้อมูลเปลี่ยนค่าตามเวลา ได้แก่ S และ t ถูกใช้เพื่อเรียนรู้และหาผลเฉลย ของ BSPDEM ด้วยสคริปต์ `btcusdt_call_pricing_mlp.py` ขั้นตอนการพัฒนา PINN มีดังนี้

1.1 กำหนดตัวแปรข้อมูลอปชันบิตคอยน์ดังตาราง 3.1

ตาราง 3.1

ตัวแปรข้อมูลอุปชันบิตคอยน์สำหรับ PINN Model A

ตัวแปร	ค่า
Strike Price, K	116000
Risk Free rate, r	0.05
Volatility, σ	0.321775
Contract duration, T	0.01916496
S_{range}	[90000, 140000]
t_{range}	[0, T]

ที่มา. จากการทดลอง

จากตาราง 3.1 ข้อมูลอุปชันบิตคอยน์ประกอบด้วยราคาใช้สิทธิ K ในหน่วย BTCUSDT อัตราดอกเบี้ยที่ปราศจากความเสี่ยง r ในหน่วย year^{-1} ค่าความผันผวน σ ในหน่วย $\text{year}^{-1/2}$ เวลาสิ้นสุดอายุสัญญา T ในหน่วย year ช่วงราคา S_{range} ในหน่วย BTCUSDT และช่วงเวลาอายุสัญญา t_{range} ในหน่วย year

1.2 กำหนดฟังก์ชัน $\text{get_diff_data}(n)$ เพื่อสร้างชุดข้อมูลฝึก $[S_{\text{range}}, t_{\text{range}}]_{\text{pde}}$ แบบสุ่ม จำนวน n ชุด สำหรับใช้ใน BSPDEM

1.3 กำหนดฟังก์ชัน $\text{get_ivp_data}(n)$ เพื่อสร้างชุดข้อมูลที่สภาวะขอบ $[S_{\text{range}}, T]_{\text{ivp}}$ และ V_{ivp} จำนวน n ชุด โมเดลจะกำหนดสภาวะขอบ IVP for $t = T$: $V = \max(S - K, 0)$ โดยที่ V_{ivp} คือผลต่างของราคา S และ K หากผลต่างราคาติดลบจะถูกกำหนดให้มีมูลค่าเป็นศูนย์ เมื่อ $[S_{\text{range}}, T]_{\text{ivp}}$ เป็นข้อมูลแบบสุ่มจำนวน n ชุด ที่เวลาสิ้นสุดอายุสัญญา $t = T$

1.4 กำหนดฟังก์ชัน $\text{get_bvp_data}(n)$ เพื่อสร้างชุดข้อมูลฝึกของ $[S_{\text{min}}, t_{\text{range}}]_{\text{bvp1}}$, V_{bvp1} และ $[S_{\text{max}}, t_{\text{range}}]_{\text{bvp2}}$, V_{bvp2} แบบสุ่มจำนวน n ชุด โมเดลจะกำหนดสภาวะขอบของราคาบิตคอยน์ที่สนใจ $S_{\text{min}} = 90000$ และ $S_{\text{max}} = 140000$ ด้วยเงื่อนไขขอบล่าง BVP1 for $S = S_{\text{min}}$: $V_{\text{bvp1}} = 0$ และเงื่อนไขขอบบน BVP1 for $S = S_{\text{min}}$: $V_{\text{bvp2}} = S_{\text{max}} - K \cdot e^{-rt}$

1.5 กำหนดคลาส (class) PINN Model A ดังตาราง 3.2

ตาราง 3.2

ข้อมูลตัวแปรในโครงสร้าง PINN Model A

ตัวแปร	ข้อมูล
N_INPUT	2
N_OUTPUT	1
N_HIDDEN	100
N_LAYERS	8
activation	Tanh()

ที่มา. จากการทดลอง

จากตาราง 3.2 โครงสร้าง PINN Model A ประกอบด้วย N_INPUT คือคุณลักษณะข้อมูลที่รับ ได้แก่ S และ t N_OUTPUT คือผลลัพธ์ของ PINN Model A หรือ ราคาประมาณอปชัน $V_{\text{pred}}(S, t)$ N_HIDDEN คือจำนวนสมการของนิวรอน $y = \sum_i \Phi(w_i x_i + b)$ หรือฟังก์ชันโหนด N_LAYERS คือจำนวนชั้นของนิวรอน และฟังก์ชันกระตุ้น (activation) $\Phi = \text{Tanh}()$

1.6 กำหนดชุดตัวแปรการฝึก PINN Model A ดังตาราง 3.3

ตาราง 3.3

ตัวแปรฝึก PINN Model A

ตัวแปร	ข้อมูล
EPOCHS	80000
LEARNING_RATE	0.0001
N_SAMPLE	8000
PHYSICS_LOSS_WEIGHT	0.1

ที่มา. จากการทดลอง

ตาราง 3.3 แสดงชุดตัวแปรฝึก PINN Model A เมื่อ EPOCHS คือ รอบการฝึกโมเดล LEARNING_RATE คือ อัตราการเรียนรู้ หรือความละเอียดการเรียนรู้ของโมเดล N_SAMPLE คือจำนวนข้อมูลที่ใช้ฝึก และ PHYSICS_LOSS_WEIGHT คือ ค่าถ่วงน้ำหนัก (β) ของ BSPDEM เพื่อปรับสมดุลค่าฟังก์ชันความสูญเสียระหว่าง $Loss_{data}$ และ $Loss_{pde}$ ให้เข้าสู่ศูนย์

1.7 เริ่มต้นโปรแกรมด้วยกระบวนการฝึก PINN โดยใช้ข้อมูลตามข้อ 1.6

1.7.1 รับชุดข้อมูล $[S_{range}, T]_{ivp}$ และ V_{ivp} จากฟังก์ชัน get_ivp_data(n) (ข้อ 1.3) จำนวน $n = N_SAMPLE$ และมาเก็บไว้

1.7.2 ใช้ชุดข้อมูล $[S_{range}, T]_{ivp}$ ในข้อ 1.7.1 และเป็นอินพุตของ PINN Model A (ข้อ 1.5) เพื่อค่าประมาณ V_{ivp_pred} และมาเก็บไว้

1.7.3 คำนวณ MSE_{ivp} จากชุดข้อมูล V_{ivp} และ V_{ivp_pred} จากข้อ 1.7.1 และ 1.7.2 ตามลำดับ ข้อมูลที่ได้รับของ MSE_{ivp} ถูกเก็บไว้

1.7.4 รับชุดข้อมูล $[S_{min}, t_{range}]_{bvp1}, V_{bvp1}$ และ $[S_{max}, t_{range}]_{bvp2}, V_{bvp2}$ จากฟังก์ชัน get_bvp_data(n) (ข้อ 2.4) จำนวน $n = N_SAMPLE$ และเก็บข้อมูลไว้

1.7.5 ชุดข้อมูล $[S_{min}, t_{range}]_{bvp1}, V_{bvp1}$ ในข้อ 1.7.4 ถูกใช้เป็นอินพุตของ PINN Model A (ข้อ 1.5) เพื่อค่าประมาณ V_{bvp1_pred} และเก็บข้อมูลไว้

1.7.6 คำนวณ MSE_{bvp1} จากชุดข้อมูล V_{ivp1} และ V_{ivp1_pred} ในข้อ 1.7.4 และ 1.7.5 ตามลำดับ ข้อมูลที่ได้รับของ MSE_{bvp1} ถูกเก็บไว้

1.7.7 ชุดข้อมูล $[S_{min}, t_{range}]_{bvp2}, V_{bvp2}$ ในข้อ 1.7.4 ถูกใช้เป็นอินพุตของ PINN Model A (จากข้อ 1.5) เพื่อค่าประมาณ V_{bvp2_pred} และเก็บข้อมูลไว้

1.7.8 คำนวณ MSE_{bvp2} จากชุดข้อมูล V_{ivp2} และ V_{ivp2_pred} ในข้อ 1.7.4 และ 1.7.6 ตามลำดับ ข้อมูลที่ได้รับของ MSE_{bvp2} ถูกเก็บไว้

1.7.9 คำนวณค่าฟังก์ชันความสูญเสีย $Loss_{ivp_bvp}$ ซึ่งมีค่าเท่ากับผลรวมของ MSE_{ivp} , MSE_{bvp1} และ MSE_{bvp2} ในข้อ 1.7.3, 1.7.6 และ 1.7.8 ตามลำดับ

1.7.10 รับชุดข้อมูล $[S_{range}, t_{range}]_{pde}$ จากฟังก์ชัน `get_diff_data(n)` (ข้อ 1.2) จำนวน $n = 4 \times N_SAMPLE$ และเก็บข้อมูลไว้

1.7.11 ชุดข้อมูล $[S_{range}, t_{range}]_{pde}$ ในข้อ 1.7.10 ถูกใช้เป็นอินพุตของ PINN Model A (ข้อ 2.5) เพื่อค่าประมาณ V_{pde_pred} และเก็บข้อมูลไว้

1.7.12 ใช้ชุดข้อมูล $[S_{range}, t_{range}]_{pde}$ และ V_{pde_pred} ในข้อ 1.7.10 และ 1.7.11 ตามลำดับ เพื่อหาอนุพันธ์เชิงอัตโนมัติสำหรับ BSPDEM ได้แก่ $(\partial V_{pde_pred} / \partial t_{range})$, $(\partial V_{pde_pred} / \partial S_{range})$, และ $(\partial^2 V_{pde_pred} / \partial S_{range}^2)$ และเก็บข้อมูลไว้

1.7.13 คำนวณค่าฟังก์ชันความสูญเสีย $Loss_{pde}$ จาก BSPDEM โดยใช้ชุดข้อมูลในข้อ 1.7.12 ข้อมูลอุปสงค์บิตคอยน์ (σ, r) ในข้อ 1.1 และ PHYSICS_LOSS_WEIGHT ในข้อ 1.6

1.7.14 คำนวณค่าฟังก์ชันความสูญเสีย $Loss_{total}$ ซึ่งมีค่าเท่ากับผลรวมของ $Loss_{ivp_bvp}$ และ $Loss_{pde}$

1.7.15 ใช้ชุดค่าฟังก์ชันความสูญเสีย $Loss_{total}$ ในข้อ 1.7.14 ปรับปรุงค่าน้ำหนัก (w, b) ของฟังก์ชันโหนดในแต่ละชั้นของนิวรอนในโครงสร้าง PINN Model A ที่ออกแบบไว้ในข้อ 1.5 โดยมีค่า LEARNING_RATE ตามที่กำหนดไว้ในข้อ 1.6

1.7.16 ทำซ้ำข้อ 1.7 จนกว่าจะครบรอบการฝึก (EPOCHS) ตามที่กำหนดในข้อ 1.6 สำหรับผลลัพธ์การเรียนรู้ที่มีประสิทธิภาพ ค่าฟังก์ชันความสูญเสีย $Loss_{total}$ จะเข้าใกล้ศูนย์ และการฝึกสิ้นสุดลงในรอบสุดท้าย PINN Model A จะถูกบันทึกและส่งออกในรูปแบบฟังก์ชันไฟล์ .pth

1.8 แสดงผลการฝึกและทดสอบประสิทธิภาพ PINN Model A

1.8.1 กำหนดฟังก์ชัน `eur_call_analytical_price(S, t, K, r,  $\sigma$ , T)` เพื่อหาผลเฉลยเชิงวิเคราะห์ (Analytical Solution) BSPDEM หรือราคา

อปชัน V_{sol} ข้อมูลอินพุต คือ S, t, K, r, σ และ T โดยใช้สมการ (30)

$$(C(S, t) = S \cdot N(d_1) - K \cdot e^{-r(T-t)} \cdot N(d_2))$$

1.8.2 สร้างกราฟการสุ่มตัวอย่างข้อมูล (Data Sampling) ของ $[S_{\text{range}}, t_{\text{range}}]_{\text{pde}}, [S_{\text{range}}, T]_{\text{ivp}}, [S_{\text{min}}, t_{\text{range}}]_{\text{bvp1}}$ และ $[S_{\text{max}}, t_{\text{range}}]_{\text{bvp2}}$ ที่ได้รับจาก ข้อ 1.2, 1.3 และ 1.4 ตามลำดับ

1.8.3 สร้างกราฟเส้นโค้งการฝึก (Training Curves) จากข้อ 1.7 ได้แก่ $Loss_{\text{total}}, Loss_{\text{ivp_bvp}}, Loss_{\text{BS}}, Loss_{\text{bvp1}}, Loss_{\text{bvp2}}$ และ $Loss_{\text{ivp}}$ ของแต่ละรอบการฝึก

1.8.4 สร้างชุดข้อมูลทดสอบแบบเมทริกซ์ 2 มิติ $[S_{\text{range}}, t_{\text{range}}]_{\text{grid}}$ จำนวน 10,000 ชุด ซึ่งประกอบด้วยแถว S_{range} จำนวน 100 ข้อมูล และคอลัมน์ t_{range} จำนวน 100 ข้อมูล และใช้ข้อมูล $[S_{\text{range}}, t_{\text{range}}]$ ในแต่ละคู่อันดับคำนวณผลเฉลยเชิงวิเคราะห์ V_{sol} โดยใช้สมการ (30)

1.8.5 สร้างกราฟในรูปแบบพื้นผิว 3 มิติ (3D Surface) เพื่อเปรียบเทียบระหว่างชุดข้อมูล $[S_{\text{range}}, t_{\text{range}}, V_{\text{sol}}]$ ที่ได้รับจากข้อ 1.8.4 และชุดข้อมูล $[S_{\text{range}}, t_{\text{range}}, V_{\text{pred}}]$ เมื่อ V_{pred} เป็นผลเฉลยที่ได้รับจาก PINN Model A จากข้อ 1.7

1.8.6 สร้างกราฟเพื่อเปรียบเทียบแบบแผนภาพกระจาย (Scatter Plot Comparison) ของ V_{sol} และ V_{pred} ในข้อ 1.8.5 และคำนวณค่ารากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

และค่าสัมประสิทธิ์สหสัมพันธ์ (Correlation; R)

$$R = \frac{\sum_{i=1}^N (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^N (y_i - \bar{y})^2 \sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})^2}}$$

เมื่อความหมายของตัวแปรในสมการแสดงดังตาราง 3.4

ตาราง 3.4

ตัวแปรของสมการ $RMSE$ และ R

ตัวแปรทั่วไป	ความหมายการวิจัย
y_i	ผลเฉลยเชิงวิเคราะห์ V_{sol}
$\hat{y}_i$	ผลเฉลยจาก PINN Model V_{pred}
$\bar{y}$	ค่าเฉลี่ยของ V_{sol} ทั้งหมด
$\bar{\hat{y}}$	ค่าเฉลี่ยของ V_{pred} ทั้งหมด
N	จำนวนข้อมูลทั้งหมด

ที่มา. จาก Dhiman, A., & Hu, Y. (2023). Physics Informed Neural Network for Option Pricing.

1.8.7 สร้างราคาปิดคอยน์จำลอง $[S, t]_{sim}$ รายชั่วโมง ด้วยสคริปต์ `generate_simulated_market_data.py` และใช้ตัวแปร K , T และ σ ดังแสดงในตาราง 3.1 (ข้อ 1.1) ข้อมูลราคาจำลองจำนวน 10 ชุด ถูกบันทึกในรูปแบบไฟล์ `simdata1.csv` ถึง `simdata10.csv` ข้อมูลราคานี้ถูกสร้างด้วยวิธีการจำลองการเคลื่อนที่แบบบราวน์เชิงเรขาคณิต (Geometric Brownian Motion; GBM)

$$S_k = S_0 \cdot \exp\left(\sum_{i=1}^k R_i\right)$$

เมื่อ $R_i = \sigma Z_i \sqrt{\Delta t}$ และความหมายของตัวแปรแสดงในตาราง 3.5

ตาราง 3.5

ความหมายตัวแปรของแบบจำลอง GBM

ตัวแปร	ความหมายการวิจัย
S_k	ราคาบิตคอยน์ ณ ตำแหน่งที่ k
S_0	ราคาเริ่มต้น (ตั้งค่าไว้ที่ราคาใช้สิทธิ)
R_i	เปอร์เซ็นต์ผลตอบแทนที่ i
σ	ค่าความผันผวน
Z_i	ตัวแปรสุ่มที่ดึงค่าจากการแจกแจงปกติ $N(0, 1)$
Δt	$T / 168$ (ขนาดของ 1 ขั้นเวลารายชั่วโมงในหน่วยปี)
$\sum_{i=1}^k R_i$	ผลรวมสะสมของผลตอบแทน

ที่มา ๗. จาก Hull, J. C. (2006). Options, Futures, and Other Derivatives (6th ed.). Pearson Prentice Hall.

1.8.8 สร้างชุดคำสั่งสคริปต์ load_model_and_predict_simdata.py เพื่อเรียกใช้ PINN Model A ในข้อ 1.7 สำหรับผลเฉลย V_{pred} ชุดข้อมูลราคาบิตคอยน์จำลอง $[S, t]_{\text{sim}}$ ในข้อ 1.8.7 ถูกใช้เพื่อประเมินประสิทธิภาพการเปรียบเทียบ V_{sol} ในข้อ 1.8.1 และ V_{pred} ที่ได้รับแสดงในรูปแบบกราฟพร้อมกับค่า RMSE และ R

1.8.9 สร้างสคริปต์ real_klines_to_csv.py เพื่อดึงข้อมูลย้อนหลังของราคาเปิด-ปิดบิตคอยน์ V_{real} และราคาบิตคอยน์ S_{real} จาก Binance API (<https://api.binance.com/>) และบันทึกเป็นไฟล์ klines.csv ลักษณะข้อมูลที่ได้รับแสดงดังตาราง 3.6

ตาราง 3.6

ข้อมูลที่ได้รับจาก *Binance API*

ข้อมูล	แหล่งข้อมูล
เวลาเปิด (openTime)	eapi/v1/klines
ราคาปิดบิตคอยน์ย้อนหลัง (close)	eapi/v1/klines
ราคาปิดบิตคอยน์ (BTCUSDT)	api/v3/klines

ที่มา. จาก *binance*, โดย Binance API, สืบค้นเมื่อ 16 พฤศจิกายน 2568, จาก <https://www.binance.com/en/binance-api>

1.8.10 สร้างสคริปต์ `load_model_and_predict_realdata.py` เพื่อเรียกใช้ PINN Model A ในข้อ 1.7 และหุดข้อมูลราคาบิตคอยน์จริงในข้อ 1.8.9 ข้อมูลทั้งสองจะถูกใช้เพื่อประเมินประสิทธิภาพ และสร้างกราฟเปรียบเทียบ V_{real} และ V_{pred} ด้วยค่า RMSE และ R

2. พัฒนา PINN แบบ 2) เพื่อฝึกและทดสอบแบบจำลอง PINN Model B ชนิดอินพุตตัว 6 ตัวแปร ได้แก่ ตัวแปรที่เปลี่ยนแปลงตามเวลา $S_1(t)$, $t_1(t)$, $\sigma_{\text{pred}}(t)$ และ $r_{\text{pred}}(t)$ และตัวแปรคงที่ K_{const} และ T_{const} การเรียนรู้เพื่อหาผลเฉลยของ BSPDEM ใช้สคริปต์ `real_btcsdt_call_pricing_mlp_6inputs.py` ขั้นตอนการพัฒนา PINN Model B มีดังนี้

2.1 สร้างชุดคำสั่งสคริปต์ `real_btcsdt_implied_params_mlp.py` เพื่อประมาณค่าชุดตัวแปร σ_{pred} และ r_{pred} ของข้อมูลตลาดจริงในข้อ 1.8.9 ชุดคำสั่งนี้เป็นสถาปัตยกรรม PINN ที่ฝึกด้วยข้อมูลจริง โดยใช้สมการ (27) เพื่อหาผลเฉลยจากราคาจริง โมเดลนี้จะถูกฝึกจนกระทั่งฟังก์ชันความสูญเสียเข้าใกล้ศูนย์และบันทึกโมเดล โมเดล PINN ที่ได้รับจะถูกใช้เพื่อประมาณค่า σ_{pred} และ r_{pred} โดยใช้ข้อมูลจาก Binance API ในข้อ 1.8.9 แล้วบันทึกข้อมูลตามตาราง 3.8 ในรูปแบบไฟล์ .csv โดยใช้ชุดตัวแปรการฝึก $\text{PINN}_{\sigma, r}$ ดังแสดงตาราง 3.7

ตาราง 3.7

ชุดตัวแปรการฝึก $PINN_{\sigma, r}$ เพื่อหา σ_{pred} และ r_{pred}

ตัวแปร	ข้อมูล
N_INPUT	2
N_OUTPUT	2
N_HIDDEN	128
N_LAYERS	8
activation	Tanh(), Softplus()

ที่มา. จากการทดลอง

ฟังก์ชันกระตุ้น Softplus() ใช้เพื่อให้ผลลัพธ์เป็นบวกเสมอ ส่วนฟังก์ชันความสูญเสียคือ

$$\text{Loss} = \frac{1}{N} \sum_{i=1}^N \left(V_{\text{pred}}^{(i)} - V_{\text{real}}^{(i)} \right)^2$$

เมื่อ V_{real} คือราคาอปชันจริง และ V_{pred} คือราคาประมาณที่ได้รับค่าจากฟังก์ชัน $\text{eur_call_analytical_price}(S, t, K, r_{\text{pred}}, \sigma_{\text{pred}}, T)$

ตาราง 3.8

ข้อมูลรวมจากข้อ 1.8.9 และ $PINN_{\sigma, r}$ ที่เพิ่มเข้ามา เมื่อ $K = 111600$ และ $T = 0.01916496$ เป็นค่าคงที่เนื่องจากพิจารณาแค่สัญญาเดียว

ข้อมูลบันทึก	ตัวแปร
btc_close_price	S_{real}
current_time_t	t_{real}
predicted_r	r_{pred}
predicted_sigma	σ_{pred}
strike_price_K	$K = 111600$
contract_duration_T	$T = 0.01916496$
close	V_{real}

ที่มา. จากการทดลอง

2.2 สร้าง PINN Model B ตัวแปรถูกกำหนดดังแสดงตาราง 3.9

ตาราง 3.9

ข้อมูล $PINN$ Model B

ตัวแปร	ข้อมูล
N_INPUT	6
N_OUTPUT	1
N_HIDDEN	128
N_LAYERS	8
activation	Tanh()

ที่มา. จากการทดลอง

PINN Model B ประกอบด้วยข้อมูลอินพุต N_INPUT ได้แก่ $S_{real}, t_{real}, \sigma_{pred}, r_{pred}, K_{const}$ และ T_{const} N_OUTPUT คือผลลัพธ์ของ PINN Model B หรือราคาประมาณอปชั่น V_{pred}

2.3 กำหนดชุดข้อมูลตัวแปรการฝึก PINN Model B ดังแสดงตาราง 3.10

ตาราง 3.10

ชุดข้อมูลตัวแปรการฝึก PINN Model B

ตัวแปร	ข้อมูล
EPOCHS	40000
LEARNING_RATE	0.0001
WARMUP_EPOCHS	5000
ANNEALING_EPOCHS	10000
PDE_WEIGHT_TARGET	0.000001

ที่มา. จากการทดลอง

WARMUP_EPOCHS คือ จำนวนรอบเริ่มต้นที่โมเดลเรียนรู้ ซึ่งใช้ข้อมูลจริง V_{real} เป็นตัวเทียบกับข้อมูล V_{pred} (ยังไม่ได้เรียน BSPDEM ตามสมการ 29 ซึ่งหมายถึง PINN ยังไม่รู้จักรการแก้สมการ BS) PINN ANNEALING_EPOCHS คือจำนวนรอบการปรับค่าถ่วงน้ำหนัก (β) ของ BSPDEM จาก 0 จนไปถึงค่าเป้าหมาย โดยใช้สมการที่ (29) ($\frac{\partial V}{\partial t} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0$) และ PDE_WEIGHT_TARGET คือค่าเป้าหมายของค่าถ่วงน้ำหนัก (β)

2.4 เริ่มต้นโปรแกรมการฝึก PINN โดยใช้ชุดตัวแปรในข้อ 2.3

2.4.1 ใช้ PINN เพื่อประมวลผล $Loss_{data}$ จากค่า V_{real} และ V_{pred} ที่ใช้อินพุต $[S_{real}, t_{real}, \sigma_{pred}, r_{pred}, K_{const}, T_{const}]$ ในข้อ 2.1 โดยใช้ข้อมูลจำนวน WARMUP_EPOCHS = 5000 รอบ

2.4.2 ใช้ PINN เพื่อประมวลผล $Loss_{pde}$ ตามสมการที่ (29) BSPDEM โดยรอบของการฝึกนับต่อจากข้อ 2.4 ไปอีก ANNEALING_

EPOCHS = 10000 รอบ ค่าเป้าหมายของค่า β คือ 0.000001 V_{pred} ที่ได้รับและข้อมูลอินพุต $[S_{\text{real}}, t_{\text{real}}, \sigma_{\text{pred}}, r_{\text{pred}}, K_{\text{const}}, T_{\text{const}}]$ จะถูกใช้เพื่อหาความสูญเสียตาม ตามสมการที่ (26) ด้วยวิธีอนุพันธ์เชิงอัตโนมัติ ค่าถ่วงน้ำหนัก (β) จะถูกปรับให้เพิ่มขึ้นที่รอบที่ WARMUP_EPOCHS สูงสุด จาก 0 ไปเป็น 0.000001 ตามสัดส่วนของรอบการฝึกต่อ ANNEALING_EPOCHS จนมีค่าเท่ากับ PDE_WEIGHT_TARGET (ตัวอย่างที่รอบ 5001 ค่า $\beta = (5001/10000) \times 0.000001 = 0.5001 \times 10^{-6}$ และตัวอย่างที่รอบ 10000 ค่า $\beta = (10000/10000) \times 0.000001 = 1 \times 10^{-6}$)

2.4.4 ปรับปรุงค่าน้ำหนัก (w, b) ของฟังก์ชันโหนดใน PINN Model B เพื่อให้ค่าความสูญเสีย $Loss_{\text{total}}$ มีค่าต่ำเข้าสู่ศูนย์ ซึ่งได้จากการรวมค่าของ $Loss_{\text{data}}$ และ $Loss_{\text{pde}}$

2.4.5 ทำซ้ำข้อ 2.4 จนกว่ารอบการฝึก (EPOCHS) จะเป็นไปตามที่กำหนดในข้อ 2.3 (40000 รอบ) ผลลัพธ์การเรียนรู้ของ PINN ที่มีประสิทธิภาพ ค่า $Loss_{\text{total}}$ เข้าใกล้ศูนย์ เมื่อสิ้นสุดรอบการฝึกสุดท้ายให้บันทึก PINN Model B ในรูปแบบไฟล์ .pth

2.5 แสดงผลการฝึกและทดสอบประสิทธิภาพ PINN model B

2.5.1 สร้างกราฟเส้นโค้งการฝึก (Training Curves) จากข้อ 2.4 ได้แก่ $Loss_{\text{total}}$, $Loss_{\text{data}}$ และ $Loss_{\text{pde}}$ ของแต่ละรอบการฝึกทั้งหมด

2.5.2 สร้างกราฟเพื่อเปรียบเทียบแบบแผนภาพกระจาย (Scatter Plot Comparison) ของ V_{real} จากข้อ 2.1 และ V_{pred} จากข้อ 2.4 โดยใช้อินพุต $[S, t]_{\text{real}}$ จากข้อ 2.1 และคำนวณค่า RMSE และ R

2.5.3 สร้างกราฟเพื่อเปรียบเทียบ V_{real} จากข้อ 2.1 และ V_{pred} โดยใช้อินพุต $[S_{\text{real}}, t_{\text{real}}, \sigma_{\text{pred}}, r_{\text{pred}}, K_{\text{const}}, T_{\text{const}}]$ จากข้อ 2.1 และคำนวณค่า RMSE และ R

3. ประยุกต์ใช้ PINN แบบ 2) เพื่อสร้างโมเดลทำนายราคาออปชันบิตคอยน์ที่เวลาถัดไปและทดสอบประสิทธิภาพการทำนายของโมเดลโดยมีขั้นตอนดังนี้

3.1 เริ่มโปรแกรมการฝึก PINN ในข้อ 2.4 โดยใช้ชุดข้อมูลและตัวแปรการฝึกจากข้อ 2.3 ชุดข้อมูลจากข้อ 2.1 [$S_{\text{real}}, t_{\text{real}}, \sigma_{\text{pred}}, r_{\text{pred}}, K_{\text{const}}, T_{\text{const}}$] จะถูกตัดออก 10 ข้อมูลสุดท้าย ดังนั้นข้อมูลที่ใช้ในการฝึก $n = N - 10$ ข้อมูลจำนวน n ใช้ฝึก PINN ตามข้อ 2.2 และบันทึกโมเดล PINN_n ในรูปแบบฟังก์ชันไฟล์ .pth_n

3.2 สร้างสคริปต์สำหรับการปรับจูนอย่างละเอียด (Fine-tuning) real_btc_usdt_call_pricing_mlp_6inputs_finetime.py และปรับ LEARNING_RATE = 0.00001 เพื่อให้ Loss ลดเข้าสู่ศูนย์ได้ดีขึ้น

3.3 ใช้สคริปต์ในข้อ 3.2 เพื่อโหลด $\text{PINN}_n.\text{pth}$ และข้อมูลจำนวน $n + 1$ ซึ่ง PINN_n จะถูกฝึกด้วยข้อมูลจำนวน $n + 1$ และบันทึกโมเดล PINN_{n+1} ในรูปแบบฟังก์ชันไฟล์ .pth

3.4 ใช้สคริปต์ในข้อ 3.2 เพื่อโหลด $\text{PINN}_{n+1}.\text{pth}$ และข้อมูลจำนวน $n + 2$ ซึ่ง PINN_{n+1} จะถูกฝึกด้วยข้อมูลจำนวน $n + 2$ และบันทึกโมเดล PINN_{n+2} ในรูปแบบฟังก์ชันไฟล์ .pth

3.5 ทำซ้ำข้อ 3.4 โหลด $\text{PINN}_{n+i}.\text{pth}$ ข้อมูลจำนวน $n + i$ ซึ่ง PINN_{n+i} จะถูกฝึกด้วยข้อมูลจำนวน $n + i$ และบันทึกโมเดล PINN_{n+1+i} ในรูปแบบฟังก์ชันไฟล์ .pth เมื่อ $i = [3, 4, 5, 6, 7, 8, 9, 10]$

3.7 ทำนายค่า V_{pred} ที่ $n+1$ (ข้อมูลที่ชั่วโม่งถัดไป) โดยใช้ PINN_{n+0} และชุดข้อมูลอินพุตที่ $n+0$ โดยใช้ค่าตัวแปรประมาณ $\sigma_{\text{pred}}, r_{\text{pred}}$ ที่ $n+1$ เหมือนกับข้อมูลที่ $n+0$ เนื่องจากมีค่าใกล้เคียงกันหรือภายใต้สมมติฐาน การเปลี่ยนแปลงเพียงเล็กน้อย โดยใช้สคริปต์ evaluate_walk_forward.py

3.8 ทำซ้ำข้อ 3.7 ทำนายค่า V_{pred} ที่ $n+i$ ตาราง 3.11

3.9 ทดสอบประสิทธิภาพการทำนายของโมเดล โดยสร้างกราฟเปรียบเทียบ V_{real} และ V_{pred} ที่ได้จาก PINN_n ถึง PINN_{n+9} และคำนวณค่า RMSE และ R เฉพาะข้อมูลที่ทำนาย

ตาราง 3.11

ระเบียบการประยุกต์ใช้ PINN Model B เพื่อทำนายอนาคต

โมเดล	ทำนาย
PINN_{n+0}	$V_{n+1}(S_{n+0}, t_{n+1}, \sigma_{n+0}, r_{n+0}, K_{\text{cons}}, T_{\text{const}})$
PINN_{n+1}	$V_{n+2}(S_{n+1}, t_{n+2}, \sigma_{n+1}, r_{n+1}, K_{\text{cons}}, T_{\text{const}})$
PINN_{n+2}	$V_{n+3}(S_{n+2}, t_{n+3}, \sigma_{n+2}, r_{n+2}, K_{\text{cons}}, T_{\text{const}})$
PINN_{n+3}	$V_{n+4}(S_{n+3}, t_{n+4}, \sigma_{n+3}, r_{n+3}, K_{\text{cons}}, T_{\text{const}})$
PINN_{n+4}	$V_{n+5}(S_{n+4}, t_{n+5}, \sigma_{n+4}, r_{n+4}, K_{\text{cons}}, T_{\text{const}})$
PINN_{n+5}	$V_{n+6}(S_{n+5}, t_{n+6}, \sigma_{n+5}, r_{n+5}, K_{\text{cons}}, T_{\text{const}})$
PINN_{n+6}	$V_{n+7}(S_{n+6}, t_{n+7}, \sigma_{n+6}, r_{n+6}, K_{\text{cons}}, T_{\text{const}})$
PINN_{n+7}	$V_{n+8}(S_{n+7}, t_{n+8}, \sigma_{n+7}, r_{n+7}, K_{\text{cons}}, T_{\text{const}})$
PINN_{n+8}	$V_{n+9}(S_{n+8}, t_{n+9}, \sigma_{n+8}, r_{n+8}, K_{\text{cons}}, T_{\text{const}})$
PINN_{n+9}	$V_{n+10}(S_{n+9}, t_{n+10}, \sigma_{n+9}, r_{n+9}, K_{\text{cons}}, T_{\text{const}})$


ที่มา. จากการทดลอง

บทที่ 4

ผลการทดลองและวิเคราะห์ข้อมูล

การทดสอบ PINN แบบ 1)


การทดสอบ PINN แบบ 1) เพื่อสร้าง PINN Model A ได้ใช้ตัวแปรข้อมูลอปชัน บิตคอยน์ดังตาราง 3.1 โดยกรอบข้อมูล S และ t ก่อนเข้าสู่กระบวนการฝึก PINN จะถูกพิจารณาอยู่บนช่วง $S_{\text{range}} = [90000, 140000]$ และ $t_{\text{range}} = [0, T]$ เมื่อ $T = 0.01916496$ (ประมาณวันหมดอายุรายสัปดาห์ในหน่วยปี) จากการกำหนดฟังก์ชัน `get_diff_data(n)`, `get_ivp_data(n)` และ `get_bvp_data(n)` เมื่อเรียกใช้ฟังก์ชันด้วยการป้อนค่าตัวแปรฝึก $N_{\text{SAMPLE}} = 8000$ ดังตาราง 3.3 (ยกเว้น `get_diff_data(n)` จะป้อนค่าตัวแปรฝึกเป็นสี่เท่าของ N_{SAMPLE} เพื่อต้องการจำนวนชุดข้อมูลฝึกที่มากกว่าค่าขอบที่มีเพียงมิติเดียว) จะได้ชุดข้อมูลสุ่ม $[S, t]$ ที่กระจายตัวอยู่ภายใต้ S_{range} และ t_{range} ดังภาพ 4.1



ภาพ 4.1 การกระจายตัวของชุดข้อมูล (Data Sampling) ที่ใช้ในการฝึก PINN Model A โดยการรันสคริปต์ `btcusdt_call_pricing_mlp.py` (result_14)

ที่มา. จากการทดลอง


การเริ่มต้นกระบวนการฝึก PINN ข้อ 1.7 (บทที่ 3) ด้วยชุดข้อมูลสุ่มที่กระจายอยู่ในภาพ 4.1 พบว่าค่า Training Curves ของ $Loss_{total}$, $Loss_{ivp_bvp}$, $Loss_{BS}$, $Loss_{bvp1}$, $Loss_{bvp2}$ และ $Loss_{ivp}$ ในหน่วย ($\times 10^{-6}$) ลดลงเข้าสู่ศูนย์อย่างพร้อมเพรียงกันซึ่งบ่งบอกถึงโมเดลสามารถเรียนรู้ได้เป็นอย่างดี ดังที่แสดงภาพรวมในภาพ 4.2 และ 4.3 โดยแสดงค่าข้อมูลการฝึก PINN Model A ในแต่ละรอบการฝึกทุกๆ 10,000 รอบ เริ่มต้นที่รอบ 1,000 ที่มีค่า $Loss_{total} = 820.27$, $Loss_{ivp_bvp} = 564.26$ และ $Loss_{BS} = 256.01$ สิ้นสุดรอบที่ 80,000 ที่มีค่า $Loss_{total} = 1.81$, $Loss_{ivp_bvp} = 1.43$ และ $Loss_{BS} = 0.38$ ตามตาราง 4.1



ภาพ 4.2 ค่า Total Loss (Moving Average) ของ Model A ที่ฝึก 80,000 รอบ โดยการรันสคริปต์ `btcusdt_call_pricing_mlp.py (result_14)`

ที่มา. จากการทดลอง

Detailed Training Curves (Moving Average)



ภาพ 4.3 ค่า Training Curves ของ $Loss_{total}$, $Loss_{ivp_bvp}$, $Loss_{BS}$, $Loss_{bvp1}$, $Loss_{bvp2}$ และ $Loss_{ivp}$ ของการฝึก PINN Model A โดยการรันสคริปต์ `btcsdt_call_pricing_mlp.py` (result_14)

ที่มา. จากการทดลอง


ตาราง 4.1

ข้อมูลการฝึก PINN Model A ในแต่ละรอบการฝึก

Epoch	Loss _{total} ($\times 10^{-6}$)	Loss _{ivp_bvp} ($\times 10^{-6}$)	Loss _{BS} ($\times 10^{-6}$)
1000	820.27	564.26	256.01
10000	47.35	44.72	2.64
20000	14.37	12.97	1.40
30000	11.40	9.93	1.48
40000	5.31	4.65	0.66
50000	3.34	2.92	0.42
60000	2.29	1.87	0.41
70000	2.03	1.55	0.48
80000	1.81	1.43	0.38


ที่มา. จากการทดลอง

โมเดลที่ได้รับจากการฝึกสำเร็จแล้วจะถูกประเมินประสิทธิภาพด้วยค่า RMSE และ R ตามสมการในข้อ 1.8.6 ของบทที่ 3 หลักๆ 2 ครั้ง ครั้งที่ 1 ด้วยชุดข้อมูลทดสอบแบบเมทริกซ์ 2 มิติ $[S_{\text{range}}, t_{\text{range}}]_{\text{grid}}$ จำนวน 10,000 ชุด ซึ่งประกอบด้วยแถว S_{range} จำนวน 100 ข้อมูล และคอลัมน์ t_{range} จำนวน 100 ข้อมูล เพื่อใช้หาราคาอุปชันบิตคอยน์จากผลเฉลยเชิงวิเคราะห์ (V_{sol}) และราคาประมาณ (V_{pred}) ผลทดสอบที่ได้พบว่าผิว 3 มิติของผลเฉลยระหว่าง V_{sol} และ V_{pred} ดังภาพ 4.4 มีความใกล้เคียงกันมาก ซึ่งสามารถวัดค่า RMSE = 47.23 และ R = 1 ดังแผนภาพกระจายในภาพ 4.5 (V_{sol})



ภาพ 4.4 การเปรียบเทียบพื้นผิว 3 มิติของผลเฉลยระหว่าง V_{sol} (ซ้าย) และ V_{pred} (ขวา) โดย
การรันสคริปต์ btcusdt_call_pricing_mlp.py (result_14)

ที่มา. จากการทดลอง



ภาพ 4.5 แผนภาพกระจายเปรียบเทียบผลเฉลยเชิงวิเคราะห์ (V_{sol}) และ ราคาประมาณจาก
PINN Model A (V_{pred}) เส้นประสีแดงคือเส้นเปรียบเทียบในอุดมคติ (Ideal Match) $y = x$
โดยการรันสคริปต์ btcusdt_call_pricing_mlp.py (result_14)

ที่มา. จากการทดลอง


ตาราง 4.2

ค่า RMSE และ R จากผลการทดสอบโมเดลด้วยชุดข้อมูลทดสอบ $[S_{range}, t_{range}]_{grid}$ จำนวน 10,000 จุด กับ PINN Model A (result_14) เทียบกับผลเฉลยเชิงวิเคราะห์

RMSE	R
47.23	1


ที่มา. จากการทดลอง

โมเดลที่ได้รับจากการฝึกสำเร็จแล้วจะถูกประเมินประสิทธิภาพด้วยค่า RMSE และ R ครั้งที่ 2 ด้วยชุดข้อมูลทดสอบ $[S, t]_{sim}$ 10 ชุด ที่ได้รับการจำลองสถานะตลาดบิตคอยน์ (ราคาเคลื่อนไหวอยู่ในกรอบเวลาหนึ่งชั่วโมง) ที่มีประเภทวันหมดอายุรายสัปดาห์ ตามข้อ 1.8.7 (บทที่ 3) การจำลองสถานะตลาดบิตคอยน์จะใช้ตัวแปร $K = 116000$, $T = 0.01916496$ และ $\sigma = 0.321775$ การประเมินประสิทธิภาพด้วยชุดข้อมูลทดสอบ $[S, t]_{sim}$ 10 ชุด (จากภาพ 4.6 ถึง 4.15) พบว่าค่าเฉลี่ยของ $RMSE = 85.18$ และ $R = 0.9899$ ดังตาราง 4.3 การประเมินประสิทธิภาพครั้งที่ 2 แสดงให้เห็นว่าแม้การเคลื่อนไหวราคาบิตคอยน์จะถูกจำลองขึ้นมาด้วยการสุ่มในรูปแบบต่าง ๆ ที่ไม่เคยเห็น แต่ PINN Model A ที่ได้รับการฝึกฝนแล้วก็ยังสามารถทำนายราคาופןชั้นบิตคอยน์ได้อย่างใกล้เคียงที่สุด




ภาพ 4.6 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจากผลเฉลยเชิงวิเคราะห์ (V_{sol}) (เส้นทึบสีน้ำเงิน) กับราคาอปชันจาก PINN Model A (V_{pred}) (เส้นประสีส้ม) บนเส้นทางราคาบิตคอยน์จำลอง (เส้นประสีเขียว) จากไฟล์ simdata01.csv โดยการรันสคริปต์ load_model_and_predict_simdata.py (result_14)

ที่มา. จากการทดลอง




ภาพ 4.7 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{sol} และ V_{pred} ของ PINN Model A บนเส้นทาง S_{sim} จากไฟล์ simdata02.csv โดยการรันสคริปต์ load_model_and_predict_simdata.py (result_14)

ที่มา. จากการทดลอง




ภาพ 4.8 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{sol} และ V_{pred} ของ PINN Model A บนเส้นทาง S_{sim} จากไฟล์ simdata03.csv โดยการรันสคริปต์ load_model_and_predict_simdata.py (result_14)

ที่มา. จากการทดลอง




ภาพ 4.9 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{sol} และ V_{pred} ของ PINN Model A บนเส้นทาง S_{sim} จากไฟล์ simdata04.csv โดยการรันสคริปต์ load_model_and_predict_simdata.py (result_14)

ที่มา. จากการทดลอง




ภาพ 4.10 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{sol} และ V_{pred} ของ PINN Model A บนเส้นทาง S_{sim} จากไฟล์ simdata05.csv โดยการรันสคริปต์ load_model_and_predict_simdata.py (result_14)

ที่มา. จากการทดลอง




ภาพ 4.11 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{sol} และ V_{pred} ของ PINN Model A บนเส้นทาง S_{sim} จากไฟล์ simdata06.csv โดยการรันสคริปต์ load_model_and_predict_simdata.py (result_14)

ที่มา. จากการทดลอง




ภาพ 4.12 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{sol} และ V_{pred} ของ PINN Model A บนเส้นทาง S_{sim} จากไฟล์ simdata07.csv โดยการรันสคริปต์ load_model_and_predict_simdata.py (result_14)

ที่มา. จากการทดลอง




ภาพ 4.13 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{sol} และ V_{pred} ของ PINN Model A บนเส้นทาง S_{sim} จากไฟล์ simdata08.csv โดยการรันสคริปต์ load_model_and_predict_simdata.py (result_14)

ที่มา. จากการทดลอง



ภาพ 4.14 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{sol} และ V_{pred} ของ PINN Model A บนเส้นทาง S_{sim} จากไฟล์ simdata09.csv โดยการรันสคริปต์ load_model_and_predict_simdata.py (result_14)

ที่มา. จากการทดลอง



ภาพ 4.15 ข้อมูลการเปรียบเทียบระหว่างราคาอปชัน V_{sol} และ V_{pred} ของ PINN Model A บนเส้นทาง S_{sim} จากไฟล์ simdata10.csv โดยการรันสคริปต์ load_model_and_predict_simdata.py (result_14)

ที่มา. จากการทดลอง

ตาราง 4.3


ค่า RMSE และ R จากผลการทดสอบ โมเดลด้วยชุดข้อมูลราคาอปชันบิตคอยน์จำลอง รายชั่วโมง $[S, t]_{sim}$ จำนวน 10 ไฟล์ (simdata1.csv ถึง simdata10.csv) กับ PINN Model A (result_14) เทียบกับผลเฉลยเชิงวิเคราะห์

Name	RMSE	R
simdata1.csv	41.12	0.9999
simdata2.csv	77.86	0.9944
simdata3.csv	111.00	0.9833
simdata4.csv	53.11	0.9983
simdata5.csv	91.25	0.9960
simdata6.csv	90.25	0.9974
simdata7.csv	91.81	0.9849
simdata8.csv	97.25	0.9645
simdata9.csv	85.20	0.9888
simdata10.csv	122.91	0.9912
Average	85.18	0.9899

ที่มา. จากการทดลอง

การประเมินประสิทธิภาพด้วยค่า RMSE และ R ทั้งสอง ครั้งก่อนหน้าบ่งบอกว่า PINN Model A สามารถเรียนรู้ฟังก์ชันภายใต้เงื่อนไขขอบของ BSPDEM ได้เป็นอย่างดี อย่างไรก็ตาม BSPDEM ที่ใช้สอนยังคงถูกกำหนดค่าตัวแปร σ และ r เป็นค่าคงที่ในโลกการเงินจริงค่าตัวแปร σ และ r ไม่ได้เป็นค่าคงในทุกชุดข้อมูล $[S, t]$ ดังนั้น PINN Model A ย่อมไม่สามารถทำนายราคาอปชันบิตคอยน์ที่ยุติธรรมได้ทั้งหมด PINN Model A จึงเป็นเพียงการประมาณค่ากลางโดยอิงจากภาพรวมของตลาดเท่านั้น เพื่อให้เห็นภาพของการเปลี่ยนแปลงของ σ และ r ในตลาดจริงงานวิจัยจึงได้สร้างชุดคำสั่งสคริปต์ตามในข้อ 2.1 (บทที่ 3) ด้วยการใช้สถาปัตยกรรม PINN ที่ฝึกโดยใช้ข้อมูล

ราคาปิดจริงของบิตคอยน์และราคาอปชันบิตคอยน์ที่ราคาใช้สิทธิ 116000 ของสัญญา BTC-250919-116000-C ในกรอบเวลาหนึ่งชั่วโมง (Time Frame: H1) ที่มีประเภทวันหมดอายุรายสัปดาห์ (เริ่มต้นวันที่ 12 กันยายน 2568 ถึง 19 กันยายน 2568) ข้อมูลของสัญญา BTC-250919-116000-C ถูกนำมาสร้างกราฟแท่งเทียนดังภาพ 4.16 ผลจากประเมินค่า σ และ r ด้วย PINN (ที่ฝึกฝนด้วยการให้โมเดลทำนายค่าตัวแปร ทั้งสองเป็นค่าบวกเสมอ) พบว่าค่าตัวแปรทั้งสองค่ามีการเปลี่ยนแปลงตามเวลาดังภาพ 4.18 และ 4.19




ภาพ 4.16 กราฟแท่งเทียนของราคาอปชันบิตคอยน์จริง V_{real} (เส้นทึบสีส้ม) และราคาบิตคอยน์จริง S_{real} (เส้นประสีเขียว) แบบรายชั่วโมงย้อนหลังที่ดึงมาจาก Binance API แท่งเทียนสีเขียวหมายถึงราคาปิดสูงกว่าราคาเปิด ส่วนแท่งเทียนสีแดงหมายถึงราคาปิดต่ำกว่าราคาเปิด โดยการรันสคริปต์ `real_btcusdt_implied_params_mlp.py (run_3)`

ที่มว. จากการทดลอง

การนำ PINN Model A มาใช้ประเมินราคาอปชันบิตคอยน์จริงจึงเป็นเพียงการประมาณค่าที่ยุติธรรมที่ดีที่สุดผ่านค่า σ ที่เป็นตัวแทนของภาพรวมตลาด และ $r = 0.05$ ที่อ้างอิงจากอัตราดอกเบี้ยปราศจากความเสี่ยงมาตรฐาน ผลที่ได้จากการประมาณแสดงไว้ในภาพ 4.17 การทดสอบประสิทธิภาพด้วย RMSE (184.78) และ R (0.8477) ดังตาราง 4.4 จึงเป็นค่าบ่งบอกว่าราคาอปชันบิตคอยน์ปิดนั้นมีความยุติธรรมมากแค่ไหนเช่น

ราคาอปชันที่ถูกซื้อขายไปนั้นถูกเกินไปหรือแพงเกินไปเมื่อเทียบกับราคาอปชัน
ยุติธรรม (หรือมองว่าเป็นค่ากลางของราคาอปชันก็ยอมได้)



ภาพ 4.17 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจริง V_{real} (เส้นทึบสีม่วง) ราคาอปชันจากผลเฉลยเชิงวิเคราะห์ V_{sol} (เส้นประสีฟ้า) และราคาอปชันประมาณ V_{pred} (เส้นประสีส้ม) จาก PINN Model A บนเส้นทางราคาบิตคอยน์จริง S_{real} จากไฟล์ klines.csv โดยการรันสคริปต์ load_model_and_predict_realddata.py

ที่มา. จากการทดลอง

ตาราง 4.4

ค่า RMSE และ R จากผลการทดสอบโมเดลด้วยชุดข้อมูลจริง


$[S, t]_{\text{real}}$ จากไฟล์ klines.csv กับ PINN Model A (result_14) เทียบกับ V_{real}

RMSE	R
184.78	0.8477

ที่มา. จากการทดลอง


การทดสอบ PINN แบบ 2)

การพัฒนา PINN แบบ 2) เพื่อสร้าง PINN Model B ได้ใช้ข้อมูลจริงของบิตคอยน์และอปชันบิตคอยน์บนสัญญา BTC-250919-116000-C ดังข้อมูลที่ถูกนำมาสร้างกราฟแท่งเทียนของราคาอปชันบิตคอยน์จริงในภาพ 4.16 รวมถึงตัวแปร σ และ r ที่ได้จาก PINN ในข้อ 2.1 (บทที่ 3) ดังที่แสดงในภาพ 4.18 และ 4.19 PINN Model B ถูกสร้างมาเพื่อเรียนรู้สถานะตลาดจริงโดยเฉพาะและทำนายราคาปีดอปชันบิตคอยน์จริง V_{pred} โดยตรง ข้อมูลอินพุตของ PINN Model B จึงประกอบไปด้วย $S_{\text{real}}, t_{\text{real}}, \sigma_{\text{pred}}, r_{\text{pred}}, K_{\text{const}}$ และ T_{const} การรับคุณลักษณะของข้อมูลถึง 6 รูปแบบเช่นนี้จะทำให้โครงข่ายประสาทเทียมสามารถเรียนรู้ถึงความสัมพันธ์เชิงลึกของข้อมูลได้อย่างหลากหลายผ่านการฝึกสอนแบบ PINN เมื่อ PINN Model B ได้เรียนรู้ตลาดที่หลากหลายมากเท่าไรก็จะยิ่งทำให้โมเดลเข้าใจกลไกตลาดได้ดียิ่งขึ้น ข้อมูลการฝึก PINN Model B จากตาราง 4.5 แสดงให้เห็นการปรับแตงน้ำหนักค่าความสูญเสียเพื่อให้ค่า $Loss_{\text{total}}, Loss_{\text{data}}$ และ $Loss_{\text{pde}}$ ลดลงเข้าสู่ค่าศูนย์อย่างพร้อมเพรียงกัน ซึ่งเป็นสัญญาณว่าโมเดลได้เรียนรู้อย่างมีประสิทธิภาพ




ภาพ 4.18 ชุดข้อมูลความผันผวน σ_{pred} (เส้นทึบสีเขียว) ที่ประมาณได้จากตลาดจริงด้วย PINN σ_r เทียบกับราคาบิตคอยน์จริง S_{real} (เส้นประสีเขียว) โดยการรันสคริปต์ `real_btcusdt_implied_params_mlp.py (run_4)`

ที่มา. จากการทดลอง



ภาพ 4.19 ชุดข้อมูลความผันผวน r_{pred} (เส้นทึบสีส้ม) ที่ประมาณได้จากตลาดจริงด้วย $\text{PINN}_{\sigma, r}$ เทียบกับราคาบิตคอยน์จริง S_{real} (เส้นประสีเขียว) โดยการรันสคริปต์ `real_btcusdt_implied_params_mlp.py` (run_4)

ที่มา. จากการทดลอง



ภาพ 4.20 ข้อมูล Training Curves แสดง $Loss_{\text{total}}$, $Loss_{\text{data}}$ และ $Loss_{\text{pde}}$ ของการฝึก PINN Model B โดยการรันสคริปต์ `real_btccusdt_call_pricing_mlp_6inputs.py` (result_8)

ที่มา. จากการทดลอง


ตาราง 4.5

ข้อมูลการฝึก PINN Model B ในแต่ละรอบการฝึก เมื่อ β คือ Current Weight

Schedule	Epoch	Loss _{total} ($\times 10^{-2}$)	Loss _{data} ($\times 10^{-2}$)	Loss _{pde}	β ($\times 10^{-6}$)	$\beta \times \text{Loss}_{pde}$ ($\times 10^{-2}$)
Warm up	1000	0.3658	0.3658	0.0000	0.0000	0.0000
	2000	0.2881	0.2881	0.0000	0.0000	0.0000
	3000	0.2600	0.2600	0.0000	0.0000	0.0000
	4000	0.2533	0.2533	0.0000	0.0000	0.0000
	5000	0.2302	0.2302	0.0000	0.0000	0.0000
Annealing	6000	9.6522	4.0796	557820	0.09	5.0203
	8000	2.7257	2.0361	22993	0.30	6.8990
	10000	3.7345	3.3400	7892	0.50	0.3946
	12000	3.5193	3.1150	5776	0.70	0.4043
	15000	7.2551	6.7835	4716	1.00	0.4716
Main Phase	20000	4.3369	4.1222	2147	1.00	0.2147
	25000	2.8357	2.6685	1672	1.00	0.1672
	30000	3.3987	3.3987	2547	1.00	0.2547
	35000	2.2175	2.1026	1148	1.00	0.1148
	40000	2.0102	1.9144	958	1.00	0.0958

ที่มา. จากการทดลอง

โมเดลที่ได้รับจากการฝึกสำเร็จแล้วจะถูกประเมินประสิทธิภาพด้วยค่า RMSE และ R ด้วยชุดข้อมูลทดสอบจริงที่ใช้ฝึก (สัญญา BTC-250919-116000-C) เพื่อประเมินว่าโมเดลเรียนรู้ได้ดีแค่ไหน ผลคือ PINN Model B สามารถเข้าใจสถานะตลาดที่ใช้ฝึกมาได้เป็นอย่างดีโดยมีค่า RMSE = 45.47 และ R = 0.9911 ดังแผนภาพกระจายเปรียบเทียบในภาพ 4.21 และข้อมูลการเปรียบเทียบราคาอปชันในภาพ 4.22



ภาพ 4.21 แผนภาพกระจายเปรียบเทียบ V_{real} (แกน Y) และ ราคาประมาณจาก PINN Model B (V_{pred}) เส้นประสีแดงคือเส้นเปรียบเทียบในอุดมคติ (Ideal Match) $y = x$ โดยการรันสคริปต์ `real_btcsdt_call_pricing_mlp_6inputs.py (result_8)`


ที่มา. จากการทดลอง

ตาราง 4.6

ค่า $RMSE$ และ R จากผลการทดสอบ PINN Model B ด้วยชุดข้อมูลอินพุตจริง $[S_{\text{real}}, t_{\text{real}}, \sigma_{\text{pred}}, r_{\text{pred}}, K_{\text{const}}, T_{\text{const}}]$ ด้วยการเทียบ V_{real} และ V_{pred}

RMSE	R
45.47	0.9911

ที่มา. จากการทดลอง




ภาพ 4.22 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจริง V_{real} (เส้นทึบสีม่วง) และราคาอปชันประมาณ V_{pred} (เส้นปะสีส้ม) จาก PINN Model B บนเส้นทางราคาบิตคอยน์จริง S_{real} โดยการรันสคริปต์ `real_btcsdt_call_pricing_mlp_6inputs.py (result_8)`

ที่มา. จากการทดลอง

การทดสอบประยุกต์ใช้ PINN แบบ 2)

จากการทดสอบ PINN แบบ 2) พบว่า PINN Model B สามารถเข้าใจในสิ่งที่เรียนรู้ได้เป็นอย่างดี จึงเป็นไปได้ว่าหากนำโมเดลที่ถูกฝึกสำเร็จแล้วนี้มาป้อนค่าเวลาถัดไป t_{n+1} โดยอิงจากข้อมูลเดิมตามลักษณะการทำนายอนาคตดังตาราง 3.11 โมเดลจะสามารถทำนายอนาคตได้ชั่วขณะ การทดสอบคือการให้ทำนายที่ข้อมูลเวลาถัดไปเป็นจำนวน 10 จุดข้อมูล (จาก PINN_{n+0} ถึง PINN_{n+9}) จากผลการทดสอบพบว่าโมเดลสามารถทำนายอนาคตได้จริงโดยสามารถวัดค่า $\text{RMSE} = 251.63$ และ $R = 0.4906$ ดังภาพ 4.23



ภาพ 4.23 ข้อมูลการเปรียบเทียบระหว่างราคาอปชันจริง V_{real} (เส้นทึบสีม่วง) และราคาอปชันประมาณ V_{pred} (เส้นปะสีส้ม) จาก PINN Model B บนเส้นทางราคาบิตคอยน์จริง S_{real} พร้อมทั้งแสดงผลการทำนายราคาอปชัน (หลังเส้นแนวตั้งสีแดง (Forecast Start)) จำนวน 10 จุดข้อมูลจาก PINN_{n+0} ถึง PINN_{n+9} แบบ Model B ลักษณะการทำนายและอินพุตดังตาราง 3.11 โดยการรันสคริปต์ `evaluate_walk_forward.py`

ที่มา. จากการทดลอง

ตาราง 4.7

ค่า RMSE และ R จากผลการทดสอบโมเดล PINN_{n+0} ถึง PINN_{n+9} ด้วยชุดข้อมูลอินพุตจริง $[S_{\text{real}}, t_{\text{real}}, \sigma_{\text{pred}}, r_{\text{pred}}, K_{\text{const}}, T_{\text{const}}]$ ด้วยการเทียบ V_{real} และ V_{pred} จำนวน 10 ตำแหน่ง

RMSE	R
251.63	0.4906

ที่มา. จากการทดลอง

บทที่ 5

สรุปผลการวิจัยและข้อเสนอแนะ

สรุปผลการวิจัย

การวิจัยนี้มีวัตถุประสงค์เพื่อศึกษาและพัฒนาแบบจำลองโครงข่ายประสาทเทียมที่ใช้ข้อมูลเชิงรู้ฟิสิกส์ (Physics Informed Neural Network: PINN) เพื่อประยุกต์ใช้กับการตั้งราคาออปชันบิตคอยน์ (Bitcoin Option Pricing) โดยอ้างอิงตาม สมการอนุพันธ์ย่อยของ Black-Scholes (BSPDEM) ผ่านกระบวนการพัฒนาและทดสอบโมเดลในรูปแบบต่างๆ ตั้งแต่การใช้ข้อมูลจำลองไปจนถึงข้อมูลตลาดจริง และการประยุกต์ใช้เพื่อทำนายราคาในอนาคต จากการทดลองพัฒนาและทดสอบประสิทธิภาพของโมเดล PINN ทั้ง 3 ส่วนหลัก ได้แก่ การพัฒนา PINN แบบ 1) (Model A) การพัฒนา PINN แบบ 2) (Model B) และการประยุกต์ใช้แบบ Walk-Forward แสดงให้เห็นถึงศักยภาพ ดังนี้ ประสิทธิภาพของ PINN แบบ 1) กับข้อมูลจำลองและทฤษฎี การพัฒนา PINN Model A ซึ่งรับอินพุตเพียง 2 ตัวแปร คือ ราคาบิตคอยน์ (S) และ เวลา (t) โดยกำหนดค่าอัตราดอกเบี้ย (r) และความผันผวน (σ) เป็นค่าคงที่ พบว่าโมเดลสามารถเรียนรู้และแก้สมการ Black-Scholes ได้อย่างมีประสิทธิภาพสูงมากเมื่อทดสอบกับ "ผลเฉลยเชิงวิเคราะห์" (Analytical Solution) และ "ข้อมูลตลาดจำลอง" (Simulated Data) ที่สร้างขึ้น 10 แบบ โดยค่าเฉลี่ย RMSE = 85.18 และค่าเฉลี่ย R = 0.9899 เมื่อนำ PINN Model A ที่ฝึกฝนด้วยค่าคงที่ r และ σ ไปทดสอบกับข้อมูลตลาดจริงจาก Binance พบว่าค่า RMSE = 184.78 และ R = 0.8477 คำนี้นบ่งบอกว่าราคาออปชันบิตคอยน์ปิดนั้นมีความยุติธรรมมากแค่ไหน เช่นราคาออปชันที่ถูกซื้อขายไปนั้นถูกเกินไปหรือแพงเกินไปเมื่อเทียบกับราคาออปชันยุติธรรม ประสิทธิภาพของ PINN แบบ 2) PINN Model B ที่มีอินพุต 6 ตัวแปร (S, t, r, σ, K และ T) (โดยค่า r และ σ นั้นได้จากการประมาณผ่านโครงข่ายประสาทเทียมอีกชุดหนึ่ง) เรียนรู้ข้อมูลราคาออปชันบิตคอยน์บนชุดข้อมูลที่ใช้ฝึกได้เป็นอย่างดี โดยมีค่า RMSE = 45.47 และค่า R = 0.9911 และในส่วนของ การประ

ยุคที่ใช้ทำนายราคาล่วงหน้า (Walk-Forward Prediction) โดยการปรับใช้ PINN แบบ 2) มาทำนายราคาอปชันในอนาคตแบบ Walk-Forward (ทำนายล่วงหน้าทีละ 1 ชั่วโมง) ด้วยเทคนิคการปรับจูนโมเดล (Fine-Tuning) อย่างต่อเนื่อง พบว่าโมเดลสามารถทำนายแนวโน้มของราคาได้จริง อย่างไรก็ตามค่าความคลาดเคลื่อน $RMSE = 251.63$ และ $R = 0.4906$ นั้นยังบ่งบอกว่าการทำนายนี้ยังไม่แม่นยำพอ และลักษณะการทำนายอนาคตยังคล้ายกับว่าโมเดลยังคงยึดรูปแบบของคำตอบเดิมอยู่

ข้อเสนอแนะ

1. การพัฒนา PINN แบบ 1) สามารถปรับโครงสร้างให้เป็นรับค่า 6 ตัวแปรได้เช่นเดียวกับ PINN แบบ 2) โดยการฝึกโมเดลจะใช้ชุดข้อมูลสุ่ม r , σ , K และ T ได้หลายช่วงค่า (แบบที่ใช้ชุดข้อมูลฝึกแบบสุ่ม S และ t) เพื่อให้ PINN ได้เรียนรู้สถานะตลาดที่หลากหลายและมีประสิทธิภาพในการประเมินราคาที่ดี
2. การพัฒนา PINN แบบ 1) และ แบบ 2) ควรทดลองปรับเปลี่ยนโครงสร้างของเครือข่าย เช่น จำนวน Layer, Hidden Nodes หรือฟังก์ชันกระตุ้นรูปแบบอื่น เพื่อหาโครงสร้างที่เหมาะสมที่สุดที่ช่วยลดเวลาในการฝึกและเพิ่มความแม่นยำให้กับ PINN Model
3. การพัฒนา PINN แบบ 2) ควรใช้ชุดข้อมูลจริงบนชนิดสัญญาอปชัน และกรอบเวลาที่หลากหลายกว่านี้ เพื่อให้ PINN เรียนรู้สถานะตลาดได้อย่างครอบคลุมที่สุดซึ่งอาจส่งผลให้การทำนายอนาคตแบบ Walk-Forward มีความแม่นยำได้

ภาคผนวก

ชุดคำสั่งคอมพิวเตอร์สำหรับการวิจัย

แหล่งดาวน์โหลดชุดคำสั่ง

ชุดคำสั่งที่พัฒนาขึ้นเพื่อใช้วิจัยในโครงการนี้

https://github.com/pornchai1889/PINN_BSPDE_Bitcoin_Options

รายชื่อและหน้าที่ของชุดคำสั่งคอมพิวเตอร์

ส่วนที่ 1 การเตรียมข้อมูล (Data Preparation)

1.1 `real_klines_to_csv.py` ใช้ดึงข้อมูลราคาแท่งเทียนย้อนหลัง (Historical Data) ของจริงจาก Binance API บันทึกเป็นไฟล์ CSV

1.2 `generate_simulated_market_data.py` ใช้สร้างชุดข้อมูลตลาดจำลองตามแนวทาง Geometric Brownian Motion (GBM) เพื่อใช้ทดสอบโมเดลในเบื้องต้น

ส่วนที่ 2 การพัฒนาและทดสอบ PINN Model A (2 Inputs)

2.1 `real_find_best_fit_sigma.py` ใช้ประมวลผลข้อมูลจริงเพื่อหาค่าความผันผวน (σ) ที่เป็นตัวแทนที่ดีที่สุดสำหรับใช้ใน Model A

2.2 `btcsdt_call_pricing_mlp.py` ใช้สร้างและฝึกฝน โมเดล PINN (Model A) โดยใช้ค่า σ และ r คงที่

2.3 `load_model_and_predict_simdata.py` ใช้โหลด Model A ที่ฝึกแล้วมาทำนายราคาอปชันเปรียบเทียบกับข้อมูลตลาดจำลอง

2.4 `load_model_and_predict_realdata.py` ใช้โหลด Model A ที่ฝึกแล้วมาทำนายราคาอปชันเปรียบเทียบกับข้อมูลตลาดจริง

ส่วนที่ 3 การพัฒนาและทดสอบ PINN Model B (6 Inputs)

3.1 `real_btcsdt_implied_params_mlp.py` ใช้หาค่าอัตราดอกเบี้ย (r) และความผันผวน (σ) แบบไม่คงที่เพื่อเป็นอินพุตให้ Model B

3.2 `real_btcdsdt_call_pricing_mlp_6inputs.py` ใช้ฝึกฝนโมเดล PINN (Model B) แบบรับอินพุต 6 ค่า เพื่อเรียนรู้สถานะตลาดที่ซับซ้อน

3.3 `real_btcdsdt_call_pricing_mlp_6inputs_finetime.py` ใช้โหลดโมเดล PINN ที่พัฒนาขึ้นแบบ Model B ที่ผ่านการฝึกแล้วมาทำการปรับจูนละเอียด (Fine-tuning) เพื่อเพิ่มความแม่นยำเฉพาะจุด

3.4 `evaluate_walk_forward.py` ใช้ทดสอบโมเดลด้วยการทำนายราคาล่วงหน้าแบบต่อเนื่อง (Walk-Forward) โดยอาศัยการ Fine-tuning ระหว่างทาง

บรรณานุกรม

- Bachelier, L. (1900). *Théorie de la spéculation*. Gauthier-Villars.
- Baydin, A. G., Pearlmutter, B. A., Radul, A. A., & Siskind, J. M. (2018). *Automatic differentiation in machine learning: a survey*. *Journal of Machine Learning Research*, 18, 1-43.
- Bayer, C., et al. (2023). *Deep neural networks for optimal stopping and calibration of local volatility models*. arXiv preprint arXiv:2305.18241.
- Black, F., & Scholes, M. (1973). *The Pricing of Options and Corporate Liabilities*. *Journal of Political Economy*, 81(3), 637-654.
- Cybenko, G. (1989). *Approximation by superpositions of a sigmoidal function*. *Mathematics of Control, Signals and Systems*, 2(4), 303-314.
- Dhiman, A., & Hu, Y. (2023). *Physics Informed Neural Network for Option Pricing*.
- Einstein, A. (1905). *Über die von der molekularkinetischen Theorie der Wärme geforderte Bewegung von in ruhenden Flüssigkeiten suspendierten Teilchen*. *Annalen der Physik*, 322(8), 549-560.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Hornik, K., Stinchcombe, M., & White, H. (1989). *Multilayer feedforward networks are universal approximators*. *Neural Networks*, 2(5), 359-366.
- Horvath, B., et al. (2021). *Deep learning volatility: A deep neural network approach to local volatility*. *Quantitative Finance*, 21(2), 195-211.
- Hull, J. C. (2015). *Options, Futures, and Other Derivatives*. Pearson.
- Hull, J. C. (2018). *Options, Futures, and Other Derivatives (10th ed.)*. Pearson.

- Mantegna, R. N., & Stanley, H. E. (1995). *Scaling behaviour in the dynamics of an economic index*. *Nature*, 376(6535), 46-49.
- Mantegna, R. N., & Stanley, H. E. (2000). *An Introduction to Econophysics: Correlations and Complexity in Finance*. Cambridge University Press.
- Merton, R. C. (1973). Theory of Rational Option Pricing. *The Bell Journal of Economics and Management Science*, 4(1), 141-183.
- quantgirluk. (n.d.). *Understanding Quantitative Finance: Arithmetic Brownian Motion*. https://quantgirluk.github.io/Understanding-Quantitative-Finance/brownian_motion_arithmetic.html
- Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). *Physics-informed Neural networks: A deep learning framework for solving forward and Inverse problems involving nonlinear partial differential equations*. *Journal of Computational Physics*, 378, 686-707.
- Reif, F. (1965). *Fundamentals of Statistical and Thermal Physics*. McGraw Hill.
- Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). *Learning representations by back-propagating errors*. *Nature*, 323(6088), 533-536.

ประวัติผู้เขียน

ชื่อ ชื่อสกุล	นายพรชัย คำแดง
วัน เดือน ปี เกิด	23 กรกฎาคม 2534
สถานที่เกิด	จังหวัดเชียงใหม่
วุฒิการศึกษา	สำเร็จการศึกษาระดับประถมศึกษาจาก โรงเรียนเทศบาลวัดเชียงยืน ปีการศึกษา 2548 สำเร็จการศึกษาระดับมัธยมศึกษาตอนต้นจาก โรงเรียนเมตตาศึกษา ปีการศึกษา 2551 สำเร็จการศึกษาระดับมัธยมศึกษาตอนปลายจาก โรงเรียนยุพราชวิทยาลัย ปีการศึกษา 2554 สำเร็จการศึกษาระดับปริญญาตรี วิศวกรรมศาสตรบัณฑิต สาขา วิชาวิศวกรรมคอมพิวเตอร์ จากมหาวิทยาลัยเทคโนโลยีราชมงคลล้านนา ปีการศึกษา 2562